



**PERBANDINGAN JARINGAN SYARAF TIRUAN
BACKPROPAGATION DAN METODE DERET BERKALA
BOX-JENKINS (ARIMA) SEBAGAI METODE
PERAMALAN CURAH HUJAN**

SKRIPSI

Diajukan Dalam Rangka Penyelesaian Studi Strata 1
Untuk Memperoleh Gelar Sarjana Sains

Disusun oleh

Nama : Anugerah PSW
Nim : 4150402021
Program Studi : Matematika S-1
Jurusan : Matematika

**FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS NEGERI SEMARANG
2007**

HALAMAN PENGESAHAN

Skripsi

Perbandingan Jaringan Syaraf Tiruan *Backpropagation*
dan Metode Deret Berkala Box-Jenkins (ARIMA) sebagai
Metode Peramalan Curah Hujan

Telah dipertahankan di hadapan sidang panitia ujian Skripsi Fakultas
Matematika dan Ilmu Pengetahuan Alam Universitas Negeri Semarang,

Hari :

Tanggal :

Ketua

Panitia Ujian,

Sekretaris

Drs. Kasmadi Imam S, M.S

NIP. 130781011

Pembimbing Utama

Drs. Supriyono, M.Si

NIP. 130815345

Ketua Penguji

Endang Sugiharti, S.Si, M.Kom

NIP. 132231407

M.Kom

Pembimbing Pembantu

Walid, S.Pd, M.Si

NIP. 132299121

Anggota Penguji

Endang Sugiharti, S.Si,

NIP. 132231407

Anggota Penguji

Drs. Arief Agoestanto, M.Si

NIP. 132046855

Drs. Arief Agoestanto, M.Si

NIP. 132046855

ABSTRAK

Anugerah PSW. 2007. *Perbandingan Jaringan Syaraf Tiruan Backpropagation dan Metode Deret berkala Box-Jenkins (ARIMA) sebagai Metode Peramalan Curah Hujan*. Skripsi. Jurusan Matematika. Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Negeri Semarang. Pembimbing Utama : Endang Sugiharti, S.Si, M.Kom. Pembimbing Pembantu : Drs. Arief Agoestanto, M.Si.

Kata kunci : *Artificial Intelligence*, ARIMA, *Backpropagation*, Box-Jenkins, Jaringan Syaraf Tiruan, *Overtraining*.

Peramalan merupakan alat penting dalam menentukan segala sesuatu agar efektif dan efisien. Selama ini banyak peramalan dilakukan secara intuitif dengan menggunakan metode-metode statistik. Metode statistik tersebut, antara lain metode *smoothing*, Box-Jenkins, ekonometri, regresi dan sebagainya. Pemilihan metode tersebut tergantung pada berbagai aspek yang mempengaruhi yaitu aspek waktu, pola data, tipe model sistem yang diamati, tingkat keakuratan *forecast* atau ramalan yang diinginkan dan sebagainya. Oleh sebab itu, akan muncul suatu masalah apabila pengamatan atau pengujian dilakukan pada suatu sistem dinamis yang memiliki sistem pola data dengan formulasi yang selalu berubah-ubah seperti halnya sistem peramalan curah hujan. Dengan menggunakan teknologi di bidang *Artificial Intelligence* yaitu teknologi jaringan syaraf tiruan maka identifikasi pola data dari sistem peramalan curah hujan dapat dilakukan dengan metode pendekatan pembelajaran atau pelatihan. Berdasarkan kemampuan belajar yang dimilikinya, maka jaringan syaraf tiruan dapat dilatih untuk mempelajari dan menganalisa pola data masa lalu dan berusaha mencari suatu formula atau fungsi yang akan menghubungkan pola data masa lalu dengan keluaran yang diinginkan. Penelitian ini bertujuan untuk mengetahui bagaimana melakukan peramalan curah hujan dengan menggunakan jaringan syaraf tiruan *backpropagation* dan untuk mengetahui besarnya tingkat keakuratan *forecast* atau ramalan yang dihasilkan oleh jaringan syaraf tiruan *backpropagation* dibandingkan dengan metode deret berkala Box-Jenkins (ARIMA).

Pada penelitian ini, prosedur yang digunakan, yaitu perumusan masalah, pengumpulan data dan analisis data yang terdiri dari perancangan model peramalan curah hujan menggunakan jaringan syaraf tiruan *backpropagation* dan membentuk model peramalan curah hujan dengan metode ARIMA.

Dari hasil perhitungan dengan menggunakan jaringan syaraf tiruan *backpropagation* yang digunakan untuk meramalkan curah hujan dari bulan Januari 2005 sampai Desember 2005 diperoleh nilai MAPE, yaitu 68.99851% sedangkan dengan metode ARIMA diperoleh nilai MAPE, yaitu 66.19905%.

Simpulan yang diperoleh yaitu peramalan dengan menggunakan jaringan syaraf tiruan *backpropagation* terdiri dari transformasi data curah hujan, pembagian data curah hujan untuk data pelatihan, data pengujian dan data validasi, perancangan struktur jaringan yang optimum dan penggunaan jaringan

yang optimum yaitu jaringan dengan struktur 12 simpul masukan, 11 simpul tersembunyi dan 1 simpul keluaran (nilai keluaran ditentukan dengan menggunakan fase 1 atau propagasi maju) dan berdasarkan nilai MAPE yang dihasilkan oleh jaringan syaraf tiruan *backpropagation* yang lebih besar dari nilai MAPE ARIMA menunjukkan bahwa tingkat keakuratan *forecast* atau ramalan dengan menggunakan metode ARIMA masih lebih baik dibandingkan dengan jaringan syaraf tiruan *backpropagation*. Saran yang diajukan yaitu transformasi data yang lain perlu dicoba untuk mendapatkan taburan data yang lebih stabil, komposisi pembagian data yang lain perlu dicoba untuk menghindari masalah *overtraining*, modifikasi pada pelatihan standar *backpropagation* selain dengan menggunakan faktor momentum perlu dicoba untuk mempercepat proses iterasi selama proses pelatihan jaringan dan model ARIMA yang lain masih perlu diteliti untuk mendapatkan nilai *error forecast* atau ramalan yang lebih kecil.

PERNYATAAN




Saya menyatakan bahwa yang tertulis dalam skripsi ini benar-benar hasil karya saya sendiri, bukan jiplakan dari karya tulis orang lain, baik sebagian ataupun seluruhnya. Pendapat atau temuan orang lain yang terdapat dalam skripsi ini dikutip atau dirujuk berdasarkan kode etik ilmiah.

Semarang, Pebruari 2007

Anugerah PSW







MOTTO DAN PERSEMBAHAN

MOTTO

-  *Dan tidak ada suatu binatang melata pun di bumi melainkan Allah-lah yang memberi rizkinya, dan Dia mengetahui tempat berdiam binatang itu dan tempat penyimpanannya. Semua tertulis dalam Kitab yang nyata (Lauh mahfuzh). (QS. 11 : 6)*
-  *Sesungguhnya rizki akan mengejar seorang hamba seperti ajal mengejanya. (Al Hadist)*
-  *Hidup adalah akumulasi dari pilihan. Konsisten pada pilihan kita merupakan hal yang wajib dijunjung. Hadapi segala rintangan dan terimalah semua risiko pilihan kita. Jangan pernah menyerah!*

PERSEMBAHAN

Persembahan ini saya buat untuk:

-  *Bapak, ibu yang kusayangi dan kuhormati, terima kasih atas segala dukungannya baik materi maupun lainnya.*
-  *Mab Dhewi, Mba Sandra, Mba Tunik, Dhe Ira dan Dhe Ezra.*
-  *Para DOSEN UNNES, terima kasih atas segala bimbingannya.*
-  *Eni, yang selalu menemani ku.*
-  *Hambali, Dunung komputer, Ipam 69, Udin gedhe & cilik, Aat, Toha, Denik, thank's untuk dukungannya.*
-  *Teman-teman Matematika angkatan 2002 yang seperjuangan.*

KATA PENGANTAR

Puji syukur ke hadirat Allah SWT yang telah memberikan nilmat dan karunia-Nya, serta kemudahan dan kelapangan, sehingga penulis dapat menyelesaikan skripsi dengan judul “Perbandingan Jaringan Syaraf Tiruan Backpropagation Dan Metode Deret Berkala Box-Jenkins (ARIMA) Sebagai Metode Peramalan Curah Hujan”.

Skripsi ini disusun sebagai syarat untuk mencapai gelar sarjana sains pada Jurusan Matematika dan Ilmu Pengetahuan Alam Universitas Negeri Semarang.

Dalam kesempatan ini, perkenankanlah penulis mengucapkan terima kasih kepada semua pihak yang telah membantu, baik dalam penelitian maupun penyusunan skripsi ini. Ucapan terima kasih ini penulis sampaikan kepada:

1. Prof. Dr. H. Sudijono Sastroatmodjo, Rektor Universitas Negeri Semarang.
2. Drs. H. Kasmadi Imam S., M.S, Dekan FMIPA Universitas Negeri Semarang yang telah memberikan ijin guna melakukan penelitian,
3. Drs. Supriyono, M.Si, Ketua Jurusan Matematika FMIPA Universitas Negeri Semarang yang telah membantu proses perijinan penelitian.
4. Endang Sugiharti, S.Si, M.Kom, Pembimbing Utama yang telah banyak memberikan bimbingan, arahan dan saran kepada penulis selama penyusunan skripsi.
5. Drs. Arief Agoestanto, M.Si, Pembimbing Pendamping yang telah banyak memberikan bimbingan, arahan dan saran kepada penulis selama penyusunan skripsi.

6. Badan Meteorologi dan Geofisika Stasiun Klimatologi Semarang yang telah memberikan data untuk penelitian ini.
7. Semua pihak yang telah membantu dalam penyusunan skripsi ini.

Penulis menyadari bahwa pengetahuan yang penulis miliki masih kurang, sehingga skripsi ini masih jauh dari sempurna. Oleh karena itu, dengan segala kerendahan hati penulis mengharap kritik dan saran yang membangun dari semua pihak guna perbaikan dan penyempurnaan tulisan berikutnya. Semoga skripsi ini dapat memberikan manfaat dan kontribusi bagi pembaca yang budiman.

Semarang, Pebruari 2007

Penulis

DAFTAR ISI

	Halaman
HALAMAN JUDUL.....	i
HALAMAN PENGESAHAN.....	ii
ABSTRAK	iii
PERNYATAAN.....	v
MOTTO DAN PERSEMBAHAN	vi
KATA PENGANTAR	vii
DAFTAR ISI.....	ix
DAFTAR TABEL.....	xi
DAFTAR GAMBAR	xii
DAFTAR LAMPIRAN.....	xiii
 BAB I. PENDAHULUAN	
A. Latar Belakang Masalah.....	1
B. Permasalahan	3
C. Tujuan Penelitian	3
D. Manfaat Penelitian	4
E. Sistematika Skripsi.....	4
 BAB II. LANDASAN TEORI	
A. Jaringan Syaraf Tiruan	6
1. Sejarah Jaringan Syaraf Tiruan6
2. Definisi Jaringan Syaraf Tiruan	7
3. Arsitektur Jaringan	10
4. Algoritma Belajar atau Pelatihan12
5. Jaringan Syaraf Tiruan Backpropagation.....	.14
6. Backpropagation Momentum.....	.20
7. Backpropagation dalam Peramalan21
B. Teknik Peramalan28
C. Metode Deret Berkala (Time Series)30

D. Analisis Deret Berkala	31
1. Alat-alat Untuk Menganalisis Data Deret Berkala.....	31
2. Aplikasi Analisis Deret Berkala.....	36
3. Metode ARIMA	38
4. Tahapan Dalam Metode ARIMA.....	41
E. Curah Hujan47
F. Matlab	48
BAB III. METODE PENELITIAN	
A. Perumusan Masalah	50
B. Pengumpulan Data50
C. Analisis Data	51
D. Penarikan Simpulan53
BAB IV. HASIL PENELITIAN DAN PEMBAHASAN	
A. Hasil Penelitian54
1. Analisis Pemilihan Struktur Jaringan Yang Optimum Dan Penggunaannya Untuk Peramalan	54
2. Analisis Data Curah Hujan Dengan Metode Deret Berkala Box-Jenkins.....	55
B. Pembahasan.....	.57
BAB V. PENUTUP	
A. Simpulan60
B. Saran.....	.61
DAFTAR PUSTAKA62
LAMPIRAN.....	.63

DAFTAR TABEL

TABEL 1	Peringkat Koefisien Pemahaman dan Momentum	25
---------	--	----

DAFTAR GAMBAR

GAMBAR 1	Sebuah Sel Syaraf Tiruan	10
GAMBAR 2	Jaringan Layar Tunggal	11
GAMBAR 3	Jaringan Layar Jamak	12

DAFTAR LAMPIRAN

LAMPIRAN 1 Data Curah Hujan Bulan Januari 1996 – Desember 2005 Kabupaten Pemalang.....	64
LAMPIRAN 2 Transformasi Linear Data Curah Hujan	65
LAMPIRAN 3 Taburan Data Curah Hujan Sebelum Transformasi	66
LAMPIRAN 4 Taburan Data Curah Hujan Setelah Transformasi	67
LAMPIRAN 5 Pola Data Pelatihan	68
LAMPIRAN 6 Pola Data Pengujian	71
LAMPIRAN 7 Pola Data Validasi.....	73
LAMPIRAN 8 Tabel Nilai Output, PE Dan MAPE Setelah Pelatihan.....	74
LAMPIRAN 9 Nilai Keluaran, PE Dan MAPE Setelah Pengujian.....	86
LAMPIRAN 10 Nilai Keluaran Jaringan 12-11-1, PE dan MAPE	92
LAMPIRAN 11 Bobot Awal dan Akhir Jaringan 12-11-1	93
LAMPIRAN 12 Plot Data Curah Hujan Dan Trend Analisisnya	95
LAMPIRAN 13 Plot Fungsi Autokorelasi Curah Hujan dan Parsialnya	96
LAMPIRAN 14 Pembedaan Musiman	97
LAMPIRAN 15 Plot Fungsi Autokorelasi Perbedaan Musim Dan Parsialnya	98
LAMPIRAN 16 Plot Fungsi Autokorelasi Sisa dan Parsialnya.....	99
LAMPIRAN 17 Nilai Output ARIMA , PE Dan MAPE.....	100

BAB I

PENDAHULUAN

A. Latar Belakang Masalah

Adanya waktu tenggang (*lead time*) antara suatu peristiwa dengan kebutuhan mendatang peristiwa itu sendiri merupakan alasan utama bagi perencanaan dan peramalan. Jika waktu tenggang ini panjang dan hasil peristiwa akhir tergantung pada faktor-faktor yang dapat diketahui maka perencanaan dapat memegang peranan penting. Dalam situasi seperti ini peramalan diperlukan untuk menetapkan kapan suatu peristiwa akan terjadi atau timbul sehingga tindakan yang tepat dapat dilakukan. Peramalan merupakan alat yang penting dalam perencanaan yang efektif dan efisien.

Selama ini banyak peramalan dilakukan secara intuitif atau dengan menggunakan metode-metode statistik. Banyak metode untuk melakukan peramalan tersebut, misalnya metode *smoothing*, Box-Jenkins, ekonometri, regresi, metode masukan-keluaran dan sebagainya. Pemilihan metode-metode tersebut yang digunakan pada perhitungan untuk meramalkan suatu hal tertentu tergantung pada berbagai aspek yang mempengaruhi yaitu aspek waktu, pola data, tipe model sistem yang diamati, tingkat keakuratan *forecast* atau ramalan yang diinginkan dan sebagainya. Karena itulah akan muncul suatu masalah apabila pengamatan atau pengujian dilakukan pada suatu sistem dinamis yang memiliki sistem pola data dengan formulasi yang selalu berubah-ubah atau dengan kata lain sistem yang memiliki tingkat kesulitan yang tinggi untuk dibuatkan formulasi modelnya pada suatu kurun waktu

tertentu seperti halnya sistem peramalan curah hujan. Disamping itu untuk menerapkan metode tersebut data harus memenuhi beberapa asumsi-asumsi yang digunakan.

Dengan menggunakan teknologi di bidang *Artificial Intelligence* yaitu teknologi jaringan syaraf tiruan maka identifikasi pola data dari sistem peramalan curah hujan dapat dilakukan dengan metode pendekatan pembelajaran atau pelatihan yaitu untuk menentukan bobot penghubung antar simpul yang optimum. Keunggulan utama jaringan syaraf tiruan adalah kemampuan komputasi yang paralel dengan cara belajar dari pola-pola yang diajarkan. Berdasarkan kemampuan belajar yang dimilikinya, maka jaringan syaraf tiruan dapat dilatih untuk mempelajari dan menganalisa pola data masa lalu dan berusaha mencari suatu formula atau fungsi yang akan menghubungkan pola data masa lalu dengan keluaran yang diinginkan pada saat ini.

Dalam peramalan didefinisikan sebuah fungsi yang menerangkan proses-proses runtun waktu (*time series*). Fungsi tersebut menentukan rangkaian perubahan melalui waktu. Fungsi tadi diperoleh dengan mencocokkan data masa lalu. Sebuah fungsi f dinotasikan $f : X \rightarrow Y$, memetakan sebuah masukan *domain* X ke sebuah lingkup keluaran Y . Untuk setiap elemen x dalam masukan *domain* X , fungsi f secara unik menentukan elemen y dalam lingkup keluaran Y . Data masa lalu diasumsikan seperti nilai-nilai fungsi. Jaringan syaraf tiruan membangun model fungsi yang menerangkan struktur dari data masa lalu tanpa memperhatikan parameter-parameter

matematik. Dengan kata lain, kaidah formula atau fungsi tidak perlu dirumuskan. Jaringan syaraf tiruan akan belajar mencari sendiri formula atau fungsi tersebut.

Dengan adanya berbagai macam arsitektur jaringan dan pelatihan yang ada pada jaringan syaraf tiruan maka dapat dipilih arsitektur jaringan dan pelatihan yang digunakan agar jaringan syaraf tiruan dapat mempelajari dan menganalisa pola data masa lalu lebih tepat sehingga diperoleh keluaran yang lebih akurat (dengan kesalahan atau *error* yang minimum).

Berdasarkan uraian di atas, maka penulis mencoba mengambil judul "Perbandingan Jaringan Syaraf Tiruan *Backpropagation* dan Metode Deret Berkala Box-Jenkins (ARIMA) sebagai Metode Peramalan Curah Hujan".

B. Permasalahan

Permasalahan yang akan dikaji dalam penelitian ini adalah sebagai berikut.

1. Bagaimana melakukan peramalan curah hujan dengan menggunakan jaringan syaraf tiruan *backpropagation*?
2. Seberapa besar tingkat keakuratan *forecast* atau ramalan yang dihasilkan oleh jaringan syaraf tiruan *backpropagation* dibandingkan dengan metode deret berkala Box-Jenkins (ARIMA)?

C. Tujuan Penelitian

Tujuan penelitian ini adalah sebagai berikut.

1. Untuk mengetahui cara kerja jaringan syaraf tiruan untuk peramalan curah hujan.
2. Untuk mengetahui keakuratan *forecast* jaringan syaraf tiruan *backpropagation* dibandingkan metode deret berkala Box-Jenkins (ARIMA).

D. Manfaat Penelitian

1. Dapat memberikan suatu metode alternatif untuk melakukan peramalan
2. Dapat bermanfaat bagi para pembaca untuk lebih mengetahui dan memahami tentang jaringan syaraf tiruan yang diaplikasikan untuk peramalan.

E. Sistematika Skripsi

Secara garis besar skripsi ini dibagi menjadi tiga bagian yaitu bagian pendahuluan, bagian isi dan bagian akhir.

A. Bagian Pendahuluan Skripsi, yang berisi :

Halaman sampul, halaman judul, lembar pengesahan, daftar isi, daftar gambar, daftar tabel, daftar lampiran-lampiran, abstrak, kata pengantar.

B. Bagian Isi Skripsi, yang berisi :

BAB I. Pendahuluan

Di dalam bab ini dikemukakan latar belakang, perumusan masalah, tujuan penelitian, manfaat penelitian dan sistematika skripsi.

BAB II. Landasan Teori

Di dalam bab ini dikemukakan konsep-konsep yang dijadikan landasan teori sebagai berikut : jaringan syaraf tiruan, teknik peramalan, metode deret berkala (*time series*), analisis deret berkala, curah hujan dan matlab.

BAB III. Metode Penelitian

Di dalam bab ini dikemukakan metode penelitian yang berisi langkah-langkah yang ditempuh untuk memecahkan masalah yaitu : identifikasi masalah, perumusan masalah, observasi, analisis data dan penarikan kesimpulan.

BAB IV. Hasil Penelitian dan Pembahasan

Di dalam bab ini dikemukakan hasil penelitian dan pembahasan yang berisi analisis aplikasi jaringan syaraf tiruan sebagai metode peramalan curah hujan di Semarang.

BAB V. Penutup

Di dalam bab ini dikemukakan simpulan dan saran.

C. Bagian Akhir Skripsi, berisi : daftar pustaka dan lampiran-lampiran.

BAB II

LANDASAN TEORI

A. Jaringan Syaraf Tiruan

1. Sejarah Jaringan Syaraf Tiruan

Jaringan syaraf tiruan telah dikembangkan sejak tahun 1940. Pada tahun 1943 McCulloch dan W.H.Pitts memperkenalkan pemodelan matematis neuron. Tahun 1949, Hebb mencoba mengkaji proses belajar yang dilakukan oleh neuron. Teori ini dikenal sebagai Hebbian Law. Tahun 1958, Rosenblatt memperkenalkan konsep perseptron suatu jaringan yang terdiri dari beberapa lapisan yang saling berhubungan melalui umpan maju (*feed foward*). Konsep ini dimaksudkan untuk memberikan ilustrasi tentang dasar-dasar intelegensi secara umum. Hasil kerja Rosenblatt yang sangat penting adalah *perceptron convergence theorem* (tahun 1962) yang membuktikan bahwa bila setiap perseptron dapat memilah-milah dua buah pola yang berbeda maka siklus pelatihannya dapat dilakukan dalam jumlah yang terbatas.

Pada tahun 1960 Widrow dan Hoff menemukan ADALINE (*Adaptive Linear Neuron*). Alat ini dapat beradaptasi dan beroperasi secara linier. Penemuan ini telah memperlebar aplikasi jaringan syaraf tiruan tidak hanya untuk pemilihan pola, tetapi juga untuk pengiriman sinyal khususnya dalam bidang *adaptive filtering*. Tahun 1969, Minsky dan Papert melontarkan suatu kritikan tentang kelemahan perseptronnya

Rosenblatt di dalam memilah-milah pola yang tidak linier. Sejak saat itu penelitian di bidang jaringan syaraf tiruan telah mengalami masa vakum untuk kurang lebih satu dasawarsa.

Tahun 1982, Hopfield telah memperluas aplikasi JST untuk memecahkan masalah-masalah optimasi. Hopfield telah berhasil memperhitungkan fungsi energi ke dalam jaringan syaraf yaitu agar jaringan memiliki kemampuan untuk mengingat atau memperhitungkan suatu obyek dengan obyek yang pernah dikenal atau diingat sebelumnya (*associative memory*). Konfigurasi jaringan yang demikian dikenal sebagai *recurrent network*. Salah satu aplikasinya adalah *Travelling Salesman Problem* (TSP).

Pada tahun 1986 Rumelhart, Hinton dan William menciptakan suatu algoritma belajar yang dikenal sebagai propagasi balik (*backpropagation*). Bila algoritma ini diterapkan pada perseptron yang memiliki lapisan banyak (*multi layer perceptron*), maka dapat dibuktikan bahwa pemilahan pola-pola yang tidak linier dapat diselesaikan sehingga dapat mengatasi kritikan yang dilontarkan oleh Minsky dan Papert.

2. Definisi Jaringan Syaraf Tiruan

Jaringan syaraf tiruan merupakan sistem pemroses informasi yang memiliki karakteristik mirip dengan jaringan syaraf biologi (Siang 2005:2). Menurut Sekarwati (2005:1), jaringan syaraf tiruan merupakan sistem komputasi yang didasarkan atas pemodelan sistem syaraf biologis

(*neurons*) melalui pendekatan dari sifat-sifat komputasi biologis (*biological computation*). Menurut Subiyanto (2002:2), jaringan syaraf tiruan adalah membuat model sistem komputasi yang dapat menirukan cara kerja jaringan syaraf biologi.

Menurut Siang (2005:2), jaringan syaraf tiruan dibentuk sebagai generalisasi model matematika dari jaringan syaraf biologi dengan asumsi sebagai berikut.

- a. Pemrosesan informasi terjadi pada banyak elemen sederhana (*neurons*).
- b. Sinyal dikirimkan diantara *neuron-neuron* melalui penghubung-penghubung.
- c. Penghubung antar *neuron* memiliki bobot yang akan memperkuat atau memperlemah sinyal.
- d. Untuk menentukan keluaran (*output*), setiap *neuron* menggunakan fungsi aktivasi yang dikenakan pada penjumlahan masukan (*input*) yang diterima. Besarnya keluaran (*output*) ini selanjutnya dibandingkan dengan suatu batas ambang.

Neuron adalah unit pemroses informasi yang menjadi dasar dalam pengoperasian jaringan syaraf tiruan (Siang 2005:23). *Neuron* terdiri dari 3 elemen pembentuk sebagai berikut.

- a. Himpunan unit-unit yang dihubungkan dengan jalur koneksi.
- b. Suatu unit penjumlah yang akan menjumlahkan masukan-masukan sinyal yang sudah dikalikan dengan bobotnya.

- c. Fungsi aktivasi yang akan menentukan apakah sinyal dari *input neuron* akan diteruskan ke *neuron* lain ataukah tidak.

Jaringan syaraf tiruan ditentukan oleh 3 hal sebagai berikut.


- a. Pola hubungan antar *neuron* (disebut arsitektur jaringan).
- b. Metode untuk menentukan bobot penghubung (disebut algoritma *training/learning/pelatihan/belajar*)
- c. Fungsi aktivasi.

Di dalam jaringan syaraf tiruan, istilah simpul (*node*) sering digunakan untuk menggantikan *neuron*.

Setiap simpul pada jaringan menerima atau mengirim sinyal dari atau ke simpul-simpul lainnya. Pengiriman sinyal disampaikan melalui penghubung. Kekuatan hubungan yang terjadi antara setiap simpul yang saling terhubung dikenal dengan nama bobot.

Model-model jaringan syaraf tiruan ditentukan oleh arsitektur jaringan serta algoritma pelatihan. Arsitektur biasanya menjelaskan arah perjalanan sinyal atau data di dalam jaringan. Sedangkan algoritma belajar menjelaskan bagaimana bobot koneksi harus diubah agar pasangan masukan-keluaran yang diinginkan dapat tercapai.

Perubahan harga bobot koneksi dapat dilakukan dengan berbagai cara, tergantung pada jenis algoritma pelatihan yang digunakan. Dengan mengatur besarnya nilai bobot ini diharapkan bahwa kinerja jaringan dalam mempelajari berbagai macam pola yang dinyatakan oleh setiap pasangan masukan-keluaran akan meningkat.



Gambar 1 Sebuah Sel Syaraf Tiruan

Pada gambar 1 diperlihatkan sebuah sel syaraf tiruan sebagai elemen penghitung. Simpul Y menerima masukan dari neuron x_1 , x_2 dan x_3 dengan bobot hubungan masing-masing adalah w_1 , w_2 dan w_3 . Argumen fungsi aktivasi adalah net masukan (kombinasi linear masukan dan bobotnya). Ketiga sinyal simpul yang ada dijumlahkan

$$\text{net} = x_1w_1 + x_2w_2 + x_3w_3 .$$

Besarnya sinyal yang diterima oleh Y mengikuti fungsi aktivasi $y = f(\text{net})$.

Apabila nilai fungsi aktivasi cukup kuat, maka sinyal akan diteruskan. Nilai fungsi aktivasi (keluaran model jaringan) juga dapat dipakai sebagai dasar untuk merubah bobot.

3. Arsitektur Jaringan (Konfigurasi Jaringan)


Berdasarkan arsitekturnya, model jaringan syaraf tiruan digolongkan menjadi:

- a. Jaringan Layar Tunggal (*Single Layer Network*)

Pada jaringan ini, sekumpulan masukan neuron dihubungkan langsung dengan sekumpulan keluarannya. Sinyal mengalir searah dari layar (lapisan) masukan sampai layar (lapisan) keluaran.

Setiap simpul dihubungkan dengan simpul lainnya yang berada di atasnya dan dibawahnya, tetapi tidak dengan simpul yang berada pada lapisan yang sama. Model yang masuk kategori ini antara lain : *ADALINE*, *Hopfield*, *Perceptron*, *LVQ*, dan lain-lain.

Pada gambar 2 diperlihatkan arsitektur jaringan layar tunggal dengan n buah masukan (x_1, x_2, \dots, x_n) dan m buah keluaran (y_1, y_2, \dots, y_m)




Gambar 2 Jaringan Layar T tunggal

b. Jaringan Layar Jamak (*Multiple Layer Network*)

Jaringan ini merupakan perluasan dari jaringan layar tunggal. Dalam jaringan ini, selain unit masukan dan keluaran, ada unit-unit lain (sering disebut layar tersembunyi). Dimungkinkan

pula ada beberapa layar tersembunyi. Model yang termasuk kategori ini antara lain : MADALINE, *backpropagation*.

Pada gambar 3 diperlihatkan jaringan dengan n buah unit masukan (x_1, x_2, \dots, x_n), sebuah layar tersembunyi yang terdiri dari m buah unit (z_1, z_2, \dots, z_m) dan 1 buah unit keluaran.



Gambar 3 Jaringan Layar Jamak

c. Jaringan Reccurent

Model jaringan *reccurent* (*reccurent network*) mirip dengan jaringan layar tunggal ataupun jamak. Hanya saja, ada simpul keluaran yang memberikan sinyal pada unit masukan (sering disebut *feedback loop*). Dengan kata lain sinyal mengalir dua arah, yaitu maju dan mundur. Contoh : *Hopfield network*, *Jordan network*, *Elmal network*.

4. Algoritma Belajar atau Pelatihan

Ide dasar jaringan syaraf tiruan adalah konsep belajar atau pelatihan. Jaringan-jaringan belajar melakukan generalisasi karakteristik tingkah laku objek.

Algoritma pelatihan artinya membentuk pemetaan (fungsi) yang menggambarkan hubungan antara vektor masukan dan vektor keluaran (Sekarwati 2005:4). Biasanya diberikan contoh yang cukup penting dalam membangun pemetaan tersebut. Walaupun untuk pasangan masukan-keluaran yang belum pernah digambarkan sebelumnya.

Untuk dapat menyelesaikan suatu permasalahan, jaringan syaraf tiruan memerlukan algoritma belajar atau pelatihan yaitu bagaimana sebuah konfigurasi jaringan dapat dilatih untuk mempelajari data historis yang ada. Dengan pelatihan ini, pengetahuan yang terdapat pada data dapat diserap dan direpresentasikan oleh harga-harga bobot koneksinya.

Menurut Siang (2005:30) algoritma belajar atau pelatihan digolongkan menjadi sebagai berikut.

a. Dengan Supervisi (*Supervised Training*)

Dalam pelatihan dengan supervisi, terdapat sejumlah pasangan data (masukan-target keluaran) yang dipakai untuk melatih jaringan. Pada setiap pelatihan, suatu masukan diberikan ke jaringan. Jaringan akan memproses dan mengeluarkan keluaran. Selisih antara keluaran jaringan dengan target (keluaran yang diinginkan) merupakan kesalahan yang terjadi. Jaringan akan memodifikasi bobot sesuai dengan kesalahan tersebut. Model yang menggunakan pelatihan

dengan supervisi antara lain : Perceptron, ADALINE, MADALINE, *Backpropagation*, LVQ.

b. Tanpa Supervisi (*Unsupervised Training*)

Dalam pelatihannya, perubahan bobot jaringan dilakukan berdasarkan parameter tertentu dan jaringan dimodifikasi menurut ukuran parameter tersebut. Model yang menggunakan pelatihan ini adalah model jaringan kompetitif.

5. Jaringan Syaraf Tiruan *Backpropagation*

Backpropagation merupakan model jaringan syaraf tiruan dengan layar jamak. Seperti halnya model jaringan syaraf tiruan lainnya, *backpropagation* melatih jaringan untuk mendapatkan keseimbangan antara kemampuan jaringan untuk mengenali pola yang digunakan selama pelatihan serta kemampuan jaringan untuk memberikan respon yang benar terhadap pola masukan yang serupa (tapi tidak sama) dengan pola yang dipakai selama pelatihan.

a. Fungsi Aktivasi pada *Backpropagation*

Dalam *backpropagation*, fungsi aktivasi yang dipakai harus memenuhi beberapa syarat sebagai berikut.

1. Kontinu.
2. Terdiferensial dengan mudah.

3. Merupakan fungsi yang tidak turun.

Salah satu fungsi yang memenuhi ketiga syarat tersebut sehingga sering dipakai adalah fungsi sigmoid biner yang memiliki *range* (0,1). Fungsi sigmoid biner didefinisikan sebagai berikut.

$$f(x) = \frac{1}{1 + e^{-x}}, -\infty \leq x \leq \infty$$

$$f'(x) = f(x)(1 - f(x))$$

Fungsi lain yang sering dipakai adalah fungsi sigmoid bipolar dengan *range* (-1,1) yang didefinisikan sebagai berikut.

$$f(x) = \frac{2}{1 + e^{-x}} - 1, -\infty \leq x \leq \infty$$

$$f'(x) = \frac{(1 + f(x))(1 - f(x))}{2}$$

Fungsi sigmoid memiliki nilai maksimum 1. Untuk pola yang targetnya lebih dari 1, pola masukan dan keluaran harus terlebih dahulu ditransformasi sehingga semua polanya memiliki range yang sama seperti fungsi sigmoid yang dipakai.

Alternatif lain adalah menggunakan fungsi aktivasi sigmoid hanya pada layer yang bukan layer keluaran. Pada layer keluaran, fungsi aktivasi yang dipakai adalah fungsi identitas $f(x) = x$.

b. Pelatihan *Backpropagation*

Seperti halnya jaringan syaraf yang lain, pada jaringan *feedforward* (umpan maju) pelatihan dilakukan dalam rangka

perhitungan bobot sehingga pada akhir pelatihan akan diperoleh bobot-bobot yang baik. Selama proses pelatihan, bobot-bobot diatur secara iteratif untuk meminimumkan *error* (kesalahan) yang terjadi. *Error* (kesalahan) dihitung berdasarkan rata-rata kuadrat kesalahan (MSE). Rata-rata kuadrat kesalahan juga dijadikan dasar perhitungan unjuk kerja fungsi aktivasi. Sebagian besar pelatihan untuk jaringan *feedforward* (umpan maju) menggunakan gradien dari fungsi aktivasi untuk menentukan bagaimana mengatur bobot-bobot dalam rangka meminimumkan kinerja. Gradien ini ditentukan dengan menggunakan suatu teknik yang disebut *backpropagation*.

Pada dasarnya, algoritma pelatihan standar *backpropagation* akan menggerakkan bobot dengan arah gradien negatif. Prinsip dasar dari algoritma *backpropagation* adalah memperbaiki bobot-bobot jaringan dengan arah yang membuat fungsi aktivasi menjadi turun dengan cepat.

Pelatihan *backpropagation* meliputi 3 fase sebagai berikut.

1. Fase 1, yaitu propagasi maju.

Pola masukan dihitung maju mulai dari layer masukan hingga layer keluaran menggunakan fungsi aktivasi yang ditentukan.

2. Fase 2, yaitu propagasi mundur.

Selisih antara keluaran jaringan dengan target yang diinginkan merupakan kesalahan yang terjadi. Kesalahan yang terjadi itu

dipropagasi mundur. Dimulai dari garis yang berhubungan langsung dengan unit-unit di layar keluaran.

3. Fase 3, yaitu perubahan bobot.

Modifikasi bobot untuk menurunkan kesalahan yang terjadi.

Ketiga fase tersebut diulang-ulang terus hingga kondisi penghentian dipenuhi.

Algoritma pelatihan untuk jaringan *backpropagation* dengan satu layer tersembunyi (dengan fungsi aktivasi sigmoid biner) adalah sebagai berikut.

a. Langkah 0

Inisialisasi semua bobot dengan bilangan acak kecil.

b. Langkah 1

Jika kondisi penghentian belum dipenuhi, lakukan langkah 2-8.

c. Langkah 2

Untuk setiap pasang data pelatihan, lakukan langkah 3-8.

d. Langkah 3 (langkah 3-5 merupakan fase 1)

Tiap unit masukan menerima sinyal dan meneruskannya ke unit tersembunyi diatasnya.

e. Langkah 4

Hitung semua keluaran di unit tersembunyi z_j ($j = 1, 2, \dots, p$).

$$z_{net_j} = v_{j0} + \sum_{i=1}^n x_i v_{ji}$$

$$z_j = f(z_{net_j}) = \frac{1}{1 + e^{-z_{net_j}}}$$

f. Langkah 5

Hitung semua keluaran jaringan di unit keluaran y_k ($k = 1, 2, \dots, m$).

$$y_net_k = w_{k0} + \sum_{j=1}^p z_j w_{kj}$$

$$y_k = f(y_net_k) = \frac{1}{1 + e^{-y_net_k}}$$

g. Langkah 6 (langkah 6-7 merupakan fase 2)

Hitung faktor δ unit keluaran berdasarkan kesalahan di setiap unit keluaran y_k ($k = 1, 2, \dots, m$).

$$\delta_k = (t_k - y_k) f'(y_net_k) = (t_k - y_k) y_k (1 - y_k), \quad t_k = \text{target}$$

keluaran

δ_k merupakan unit kesalahan yang akan dipakai dalam perubahan bobot layar dibawahnya.

Hitung perubahan bobot w_{kj} dengan laju pemahaman α .

$$\Delta w_{kj} = \alpha \delta_k z_j, \quad k = 1, 2, \dots, m; j = 0, 1, \dots, p$$

h. Langkah 7

Hitung faktor δ unit tersembunyi berdasarkan kesalahan di setiap unit tersembunyi z_j ($j = 1, 2, \dots, p$).

$$\delta_net_j = \sum_{k=1}^m \delta_k w_{kj}$$

Faktor δ unit tersembunyi.

$$\delta_j = \delta_net_j f'(z_net_j) = \delta_net_j z_j (1 - z_j)$$

Hitung suku perubahan bobot v_{ji} .

$$\Delta v_{ji} = \alpha \delta_j x_i, j = 1, 2, \dots, p; i = 1, 2, \dots, n$$

i. Langkah 8 (fase 3)

Hitung semua perubahan bobot. Perubahan bobot garis yang menuju ke unit keluaran, yaitu:

$$w_{kj}(\text{baru}) = w_{kj}(\text{lama}) + \Delta w_{kj}, (k = 1, 2, \dots, m; j = 0, 1, \dots, p).$$

Perubahan bobot garis yang menuju ke unit tersembunyi, yaitu:

$$v_{ji}(\text{baru}) = v_{ji}(\text{lama}) + \Delta v_{ji}, (j = 1, 2, \dots, p; i = 0, 1, \dots, n).$$

Parameter α merupakan laju pemahaman yang menentukan kecepatan iterasi. Nilai α terletak antara 0 dan 1 ($0 \leq \alpha \leq 1$). Semakin besar harga α , semakin sedikit iterasi yang dipakai. Akan tetapi jika harga α terlalu besar, maka akan merusak pola yang sudah benar sehingga pemahaman menjadi lambat. Satu siklus pelatihan yang melibatkan semua pola disebut *epoch*.

Pemilihan bobot awal sangat mempengaruhi jaringan syaraf tiruan dalam mencapai minimum global (atau mungkin lokal saja) terhadap nilai *error* (kesalahan) dan cepat tidaknya proses pelatihan menuju kekonvergenan.

Apabila bobot awal terlalu besar maka *input* (masukan) ke setiap lapisan tersembunyi atau lapisan *output* (keluaran) akan jatuh pada daerah dimana turunan fungsi sigmoidnya akan sangat kecil. Apabila bobot awal terlalu kecil, maka *input* (masukan) ke setiap lapisan

tersembunyi atau lapisan *output* (keluaran) akan sangat kecil. Hal ini akan menyebabkan proses pelatihan berjalan sangat lambat. Biasanya bobot awal diinisialisasi secara random dengan nilai antara -0.5 sampai 0.5 (atau -1 sampai 1 atau interval yang lainnya).

Setelah pelatihan selesai dilakukan, jaringan dapat dipakai untuk pengenalan pola. Dalam hal ini, hanya propagasi maju (langkah 4 dan 5) saja yang dipakai untuk menentukan keluaran jaringan.

6. *Backpropagation Momentum*

Pada standar backpropagation, perubahan bobot didasarkan atas gradien yang terjadi untuk pola yang dimasukkan saat itu. Modifikasi yang dapat dilakukan adalah melakukan perubahan bobot yang didasarkan atas arah gradien pola terakhir dan pola sebelumnya (disebut momentum) yang dimasukkan. Jadi tidak hanya pola masukan terakhir saja yang diperhitungkan.

Penambahan momentum dimaksudkan untuk menghindari perubahan bobot yang mencolok akibat adanya data yang sangat berbeda dengan yang lain (*outlier*). Apabila beberapa data terakhir yang diberikan ke jaringan memiliki pola serupa (berarti arah gradien sudah benar), maka perubahan bobot dilakukan secara cepat. Namun apabila data terakhir yang dimasukkan memiliki pola yang berbeda dengan pola sebelumnya, maka perubahan bobot dilakukan secara lambat.

Dengan penambahan *momentum*, bobot baru pada waktu ke $(t+1)$ didasarkan atas bobot pada waktu t dan $(t-1)$. Disini harus ditambahkan

dua variabel yang mencatat besarnya momentum untuk dua iterasi terakhir. Jika μ adalah konstanta ($0 \leq \mu \leq 1$) yang menyatakan parameter momentum maka bobot baru dihitung berdasarkan persamaan sebagai berikut.

$$w_{kj}(t+1) = w_{kj} + \alpha \delta_k z_j + \mu(w_{kj}(t) - w_{kj}(t-1))$$

dengan,

$w_{kj}(t)$ = bobot awal pola kedua (hasil dari iterasi pola pertama).

$w_{kj}(t-1)$ = bobot awal pada iterasi pola pertama.

dan

$$v_{ji}(t+1) = v_{ji}(t) + \alpha \delta_k x_i + \mu(v_{ji}(t) - v_{ji}(t-1))$$

dengan,

$v_{ji}(t)$ = bobot awal pola kedua (hasil iterasi pola pertama).

$v_{ji}(t-1)$ = bobot awal pada iterasi pertama.

(Siang

2005:113)

7. *Backpropagation* dalam Peramalan

Salah satu bidang, backpropagation dapat diaplikasikan dengan baik adalah bidang peramalan (*forecasting*). Peramalan yang sering diketahui adalah peramalan besarnya penjualan, nilai tukar valuta asing, prediksi besarnya aliran sungai dan lain-lain.

Secara umum, masalah peramalan dapat dinyatakan dengan sejumlah data runtun waktu (*time series*) x_1, x_2, \dots, x_n . Masalahnya adalah memperkirakan berapa harga x_{n+1} berdasarkan x_1, x_2, \dots, x_n .

Langkah-langkah membangun struktur jaringan untuk peramalan sebagai berikut.

1. Transformasi Data

Langkah awal sebelum melakukan proses pelatihan pada jaringan yang akan digunakan untuk peramalan adalah transformasi data. Sebab-sebab utama data ditransformasi adalah agar kestabilan taburan data dicapai. Selain itu berguna untuk menyesuaikan nilai data dengan *range* fungsi aktivasi yang digunakan dalam jaringan (Siang 2005:121). Ada beberapa transformasi yang digunakan, yaitu transformasi polinomial, transformasi normal dan transformasi linear. Nilai hasil transformasi polinomial, normal dan linear dapat diperoleh dengan persamaan sebagai berikut.

a. Transformasi Polinomial

$$x' = \ln x$$

dengan,

x' = nilai data setelah transformasi polinomial.

x = nilai data aktual.

b. transformasi Normal

$$x_n = \frac{x_0 - x_{\min}}{x_{\max} - x_{\min}}$$

dengan,

x_n = nilai data normal.

x_0 = nilai data aktual.

x_{\min} = nilai minimum data aktual keseluruhan.

x_{\max} = nilai maksimum data aktual keseluruhan.

c. Transformasi Linear pada selang $[a, b]$

$$x' = \frac{(x - x_{\min})(b - a)}{x_{\max} - x_{\min}} + a$$

(Siang.2005:121)

dengan,

x' = nilai data setelah transformasi linear.

x = nilai data aktual.

x_{\min} = nilai minimum data aktual keseluruhan.

x_{\max} = nilai maksimum data aktual keseluruhan.

2. Pembagian Data

Langkah selanjutnya setelah transformasi data adalah pembagian data.

Data dibagi menjadi data pelatihan, pengujian dan validasi. Beberapa komposisi data pelatihan, pengujian dan validasi yang sering digunakan adalah sebagai berikut.

- a. 80% untuk data pelatihan dan 20% untuk data pengujian dan validasi.

- b. 70% untuk data pelatihan dan 30% untuk data pengujian dan validasi.
- c. $\frac{2}{3}$ untuk data pelatihan dan $\frac{1}{3}$ untuk data pengujian dan validasi.
- d. 50% untuk data pelatihan dan 50% untuk data pengujian dan validasi.
- e. 60% untuk data pelatihan dan 40% untuk data pengujian dan validasi.

Aspek pembagian data harus ditekankan agar jaringan mendapat data pelatihan yang secukupnya dan data pengujian dapat menguji prestasi pelatihan yang dilakukan berdasarkan nilai MAPE data pelatihan dan pengujian. Bilangan data yang kurang untuk proses pelatihan akan menyebabkan jaringan mungkin tidak dapat mempelajari taburan data dengan baik. Sebaliknya, data yang terlalu banyak untuk proses pelatihan akan melambatkan proses pemusatan (konvergensi). Masalah *overtraining* (data pelatihan yang berlebihan) akan menyebabkan jaringan cenderung untuk menghafal data yang dimasukan daripada mengeneralisasi.

3. Perancangan Struktur Jaringan Yang Optimum

Langkah selanjutnya setelah pembagian data adalah penentuan bilangan simpul masukan, bilangan lapisan tersembunyi, bilangan simpul lapisan tersembunyi dan bilangan simpul keluaran yang akan digunakan dalam jaringan. Terdapat beberapa aturan yang dapat membantu perancangan jaringan yang optimum, yaitu sebagai berikut.

- a. Bilangan simpul masukan sama dengan periode dimana data berfluktuasi.
- b. Bilangan simpul keluaran sama dengan bilangan keluaran masalah.
- c. Mulai dengan satu lapisan tersembunyi dan digunakan lebih dari satu lapisan tersembunyi jika diperlukan.
- d. Jika menggunakan satu lapisan tersembunyi, bilangan simpul tersembunyi awal adalah 75% dari bilangan simpul masukan.

Penggunaan jaringan dengan dua atau lebih lapisan tersembunyi dalam masalah peramalan kebanyakan tidak akan memberikan pengaruh yang sangat besar terhadap prestasi jaringan untuk melakukan peramalan. Selain itu akan melambatkan proses pelatihan yang disebabkan bertambahnya simpul.

Beberapa kaedah untuk memperkirakan bilangan simpul tersembunyi yaitu sebagai berikut.

- a. $h = n, 2n$
- b. $h = n/2$

dengan

n = bilangan simpul masukan yang digunakan.

h = bilangan simpul tersembunyi.

Penentuan bilangan simpul tersembunyi yang terbaik diperoleh secara *trial and error* dari simpul 1 sampai $2n$.

4. Pemilihan Koefisien Pemahaman dan Momentum

Pemilihan koefisien pemahaman dan momentum mempunyai peranan yang penting untuk struktur jaringan yang akan dibangun. Dalam pembangunan jaringan yang akan digunakan dalam peramalan, hasil keputusan yang kurang memuaskan dapat diperbaiki dengan penggunaan koefisien pemahaman dan momentum secara *trial and error* untuk mendapatkan nilai bobot yang paling optimum agar MAPE dan MSE jaringan dapat diperbaiki. Berdasarkan pengalaman dan aplikasi jaringan syaraf tiruan dalam berbagai masalah peramalan diperoleh nilai-nilai koefisien pemahaman dan momentum seperti pada tabel 1 di bawah ini.

Tabel 1 Peringkat Koefisien Pemahaman dan Momentum

Peringkat	1	2	3	4
Koefisien Pemahaman	0.9	0.7	0.5	0.4
Koefisien Momentum	0.1	0.4	0.5	0.6

5. Memilih dan Menggunakan Struktur Jaringan yang Optimum

Jaringan yang dibangun akan dinilai keakuratan ramalannya. Kaedah penilaian yang digunakan adalah nilai *Percentage Error* (PE), *Mean Absolute Percentage Error* (MAPE) dan *Mean Square Error* (MSE).

Pendekatan MAPE digunakan untuk menilai prestasi jaringan yang dilatih karena MAPE mengenal secara pasti signifikansi hubungan diantara data ramalan dengan data aktual melalui persentase dari data aktual serta indikator positif atau negatif pada galat (*error*) diabaikan. Ketepatan model diukur secara relatif menggunakan PE dan dilihat juga dari nilai MSE-nya. Nilai PE, MAPE dan MSE didapat dari persamaan di bawah ini.

$$PE = \frac{(y_t - \hat{y}_t)}{y_t} \times 100\%$$

(Makridakis.1999:61)

dengan,

y_t = nilai aktual pada waktu t.

\hat{y}_t = nilai ramalan pada waktu t.

$$MAPE = \sum_1^n \frac{|PE|}{n}$$

(Makridakis.1999:61)

dengan,

n = bilangan ramalan.

|PE| = nilai absolut PE

$$MSE = \frac{1}{n} \sum_{i=1}^n e_i^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)$$

(Makridakis.1999:59)

dengan,

n = bilangan ramalan.

y_t = nilai aktual pada waktu t .

\hat{y}_t = nilai ramalan pada waktu t .

Berdasarkan nilai MAPE dan PE yang terendah dari proses pelatihan diperoleh jaringan yang optimum. Keakuratan ramalan jaringan dilihat dari nilai MAPE, MSE dan PE dari proses pengujian dan validasi.

6. Pemilihan jaringan optimum dan penggunaannya untuk peramalan
Langkah-langkah pemilihan jaringan yang optimum sebagai berikut.
 - a. Proses pelatihan dilakukan terhadap data pelatihan dengan struktur jaringan yang memiliki bilangan simpul tersembunyi berbeda akan diperoleh nilai keluaran jaringan. Nilai PE, MAPE dan MSE-nya dihitung. Jaringan dengan nilai MAPE terendah dipilih sebagai jaringan yang optimum untuk digunakan dalam peramalan.
 - b. Setelah proses pelatihan dilakukan proses pengujian terhadap data pengujian dengan struktur jaringan yang memiliki bilangan simpul tersembunyi berbeda yang telah dilatih akan diperoleh nilai keluaran jaringan. Nilai PE, MAPE dan MSE masing-masing struktur jaringan dihitung. Proses pengujian dilakukan untuk menguji prestasi pelatihan dan sebagai pendukung bahwa jaringan terpilih sebagai jaringan yang tepat untuk model peramalan.
 - c. Proses validasi dilakukan dengan menggunakan jaringan terpilih terhadap data validasi untuk melihat prestasi ramalannya.

B. Teknik Peramalan

Situasi peramalan sangat beragam dalam horison waktu peramalan, faktor yang menentukan hasil sebenarnya, tipe pola data dan berbagai aspek lainnya. Untuk menghadapi penggunaan yang luas seperti itu, beberapa teknik telah dikembangkan. Teknik tersebut dibagi ke dalam dua kategori utama yaitu metode kualitatif atau teknologis dan metode kuantitatif (Makridakis,dkk 1995:8).

Metode kualitatif atau teknologis membutuhkan *input* (masukan) yang tergantung pada metode tertentu dan biasanya merupakan hasil dari pemikiran intuitif, prakiraan (*judgment*) dan pengetahuan yang telah didapat. Metode teknologis dibagi menjadu dua bagian sebagai berikut.

1. Metode Eksploratoris

Dimulai dengan masa lalu dan masa kini sebagai titik awalnya dan bergerak ke arah masa depan secara heuristik, seringkali dengan melihat semua kemungkinan yang ada. Yang termasuk metode ini antara lain Dalphi, kurva-S, analogi dan penelitian morfologis.

2. Metode Normatif

Dimulai dengan menetapkan sasaran dan tujuan yang akan datang, kemudian bekerja mundur untuk melihat apakah hal ini dapat dicapai berdasarkan kendala, sumber daya dan teknologi yang tersedia. Yang termasuk metode ini antara lain matrik keputusan, pohon relevansi (*relevance tree*) dan analisis sistem.

Metode kuantitatif dapat diterapkan bila terdapat tiga kondisi yaitu sebagai berikut.

1. Tersedia informasi tentang masa lalu.
2. Informasi tersebut dapat dikuantitatifkan dalam bentuk data numerik.
3. Dapat diasumsikan bahwa beberapa aspek pola masa lalu akan terus berlanjut di masa mendatang.

Kondisi yang terakhir ini dikenal sebagai asumsi kesinambungan (*assumption of continuity*). Asumsi ini merupakan premis yang mendasari semua metode peramalan kuantitatif.

Metode kuantitatif dapat dibagi menjadi dua bagian yaitu sebagai berikut.

1. Metode Runtun Waktu (*Time Series*)

Pendugaan masa depan dilakukan berdasarkan nilai masa lalu dari variabel atau kesalahan masa lalu. Tujuan metode ini adalah menemukan pola dalam deret data historis dan mengekstrapolasikan ke masa depan.

2. Metode Kausal

Mengasumsikan bahwa faktor yang diramalkan menunjukkan suatu hubungan sebab akibat dengan satu atau lebih variabel bebas.

C. Metode Deret Berkala (*Time Series*)

Metode deret berkala (*time series*) bertujuan untuk menggolongkan dan memahami sistem serta meramalkan sifatnya untuk masa depan. Jika ada persamaan yang ditentukan maka sifat sistem dapat diketahui dengan menyelesaikan persamaan tersebut yang kondisi awalnya sudah diketahui. Pada peramalan runtun waktu, persamaan dan kondisi awal mungkin diketahui kedua-duanya atau mungkin hanya salah satu saja. Oleh karena itu diperlukan suatu aturan untuk menentukan perkembangan dan keakuratan sistem. Penentuan aturan tersebut mungkin mengacu dari pencocokkan data masa lalu.

Menurut Gershenfeld dan Weigend (Bose 1996:347) ada tiga tujuan dari metode runtun waktu yaitu sebagai berikut.

1. Peramalan (*forecasting*) berusaha memperkirakan perkembangan sistem untuk jangka pendek.
2. Pemodelan (*modeling*) berusaha menemukan gambaran tentang keakuratan sifat sistem untuk jangka panjang.
3. Penggolongan digunakan untuk menentukan sifat-sifat utama dari sistem.

Tiga tujuan tersebut berhubungan tetapi mungkin tidak sama. Pemodelan dapat digunakan untuk peramalan (*forecasting*) jangka pendek tetapi mungkin kemampuan untuk melakukan hal tersebut kurang maksimal dan sebaliknya.

Langkah penting dalam memilih suatu metode runtun waktu (*time series*) yang tepat adalah dengan mempertimbangkan jenis pola data sehingga metode yang paling tepat dengan pola tersebut dapat diuji. Pola data dapat dibedakan menjadi empat yaitu sebagai berikut.

1. Pola horisontal terjadi bilamana nilai data berfluktuasi di sekitar nilai rata-rata yang tetap.
2. Pola musiman terjadi bilamana suatu runtun dipengaruhi oleh faktor musiman.
3. Pola siklis terjadi bilamana datanya dipengaruhi oleh faktor ekonomi jangka panjang seperti berhubungan dengan siklus bisnis.
4. Pola *trend* terjadi bilamana terdapat kenaikan atau penurunan sekuler jangka panjang dalam data.

Banyak runtun data yang mencakup kombinasi dari pola-pola diatas. Metode peramalan yang dapat membedakan setiap pola harus dipakai bila diinginkan adanya pemisahan komponen data tersebut. Demikian pula, metode peramalan alternatif dapat digunakan untuk mengenali pola dan mencocokkan data secara tepat sehingga nilai mendatang dapat diramalkan.

D. Analisis Deret Berkala

1. Alat-alat Untuk Menganalisis Data Deret Berkala

a. Plot Data

Langkah pertama yang baik untuk menganalisi data deret berkala adalah memplot data tersebut secara grafis. Hal ini bermanfaat untuk memplot berbagai data *moving average* untuk menetapkan adanya *trend* (penyimpangan nilai tengah) dan adanya pengaruh musiman pada data (*deseasonalize the data*).

b. Koefisien Autokorelasi

Statistik kunci di dalam analisis deret berkala adalah koefisien autokorekasi (koefisien deret berkala dengan deret berkala itu sendiri yang mempunyai selisih waktu (*lag*) 0,1, 2 periode atau lebih. Misal dipunyai persamaan sebagai berikut.

$$y_t = a + \phi_1 y_{t-1} + \phi_2 y_{t-2} + e_t.$$

(1)

Persamaan (1) adalah model AR (ARIMA (2,0,0)) yang menggambarkan y_t sebagai suatu kombinasi linear dari dua nilai sebelumnya. Koefisien korelasi sederhana antara y_t dengan y_{t-1} dapat dicari dengan menggunakan persamaan sebagai berikut.

$$\begin{aligned} r_{y_t y_{t-1}} &= \frac{(\text{ko variansi antara } y_t \text{ dan } y_{t-1})}{(\text{deviasi standar } y_t)(\text{deviasi standar } y_{t-1})} \\ &= \frac{\sum_{t=2}^n (y_t - \bar{y}_t)(y_{t-1} - \bar{y}_{t-1})}{\sqrt{\sum_{t=1}^n (y_t - \bar{y}_t)^2} \sqrt{\sum_{t=2}^n (y_{t-1} - \bar{y}_{t-1})^2}}. \end{aligned}$$

(2)

Misal data y_t diasumsikan stasioner (baik nilai tengah maupun variansinya) sehingga kedua nilai tengah \bar{y}_t dan \bar{y}_{t-1} dapat diasumsikan bernilai sama ($\bar{y} = \bar{y}_t = \bar{y}_{t-1}$) dan dua deviasi standar dapat diukur satu kali saja yaitu dengan menggunakan seluruh data y_t yang diketahui.

Dengan menggunakan asumsi-asumsi penyederhanaan ini, maka persamaan (2) menjadi sebagai berikut.

$$r_{y_t y_{t-1}} = \frac{\sum_{t=2}^n (y_t - \bar{y})(y_{t-1} - \bar{y})}{\sum_{t=1}^n (y_t - \bar{y})^2} .$$

(3)

Persamaan (3) dapat berlaku umum dan dapat digunakan untuk seluruh *time-lag* dari satu periode untuk suatu deret berkala. Hal ini sebagai akibat adanya asumsi stasioneritas.

Autokorelasi untuk *time-lag* 1, 2, 3,..., k dapat dicari dan dinotasikan r_k sebagai berikut.

$$r_k = \frac{\sum_{t=1}^{n-k} (y_t - \bar{y})(y_{t+k} - \bar{y})}{\sum_{t=1}^n (y_t - \bar{y})^2} .$$

(4)

Suatu koefisien autokorelasi perlu dikaji untuk menentukan apakah secara statistik nilainya berbeda secara signifikan dari nol atau tidak.

Untuk itu perlu dihitung galat standar dari r_k dengan rumus sebagai berikut.

$$se_{r_k} = \frac{1}{\sqrt{n}}$$

dengan,

n menunjukkan banyaknya data.

Koefisien autokorelasi dari data random mempunyai distribusi sampling yang mendekati kurva normal dengan nilai tengah nol dan kesalahan standar $\frac{1}{\sqrt{n}}$. Dari nilai kesalahan standar se_{rk} dan sebuah nilai interval kepercayaan dapat diperoleh sebuah rentang nilai. Suatu koefisien autokorelasi disimpulkan tidak berbeda secara signifikan apabila nilainya berada pada rentang nilai tersebut dan sebaliknya.

c. Koefisien Autokorelasi Parsial

Di dalam analisis regresi, apabila variabel tidak bebas Y diregresikan kepada variabel-variabel bebas X_1 dan X_2 maka dipertanyakan sejauh mana variabel X mampu menerangkan keadaan Y apabila mula-mula X_2 dipisahkan. Ini berarti meregresikan Y kepada X_2 dan menghitung galat sisa (*residual error*) kemudian meregresikan lagi nilai sisa tersebut kepada X_1 . Di dalam analisis deret berkala juga berlaku konsep yang sama.

Autokorelasi parsial digunakan untuk mengukur tingkat keeratan (*association*) antara X_t dan X_{t-k} apabila pengaruh dari time-lag 1, 2, 3,..., k-1 dianggap terpisah. Koefisien autokorelasi parsial berorde m didefinisikan sebagai koefisien autoregresif terakhir dari model AR (m). Dibawah ini merupakan persamaan-persamaan yang masing-masing digunakan untuk menetapkan AR (1), AR (2), AR (3),..., AR (m-1) dan proses AR (m).

$$X_t = \hat{\phi}_1 X_{t-1} + e_{t-1}.$$

(5)

$$X_t = \phi_1 X_{t-1} + \hat{\phi}_2 X_{t-2} + e_t.$$

(6)

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \hat{\phi}_3 X_{t-3} + e_t.$$

(7)

⋮

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \dots + \hat{\phi}_{m-1} X_{t-m+1} + e_t.$$

(8)

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \dots + \phi_{m-1} X_{t-m+1} + \hat{\phi}_m X_{t-m} + e_t.$$

(9)

Dari persamaan-persamaan di atas dapat dicari nilai-nilai taksiran

$\hat{\phi}_1, \hat{\phi}_2, \hat{\phi}_3, \dots, \hat{\phi}_{m-1}, \hat{\phi}_m$ berdasarkan pada koefisien autokorelasi. Apabila

ruas kiri dan kanan persamaan (5) dikalikan dengan X_{t-1} menjadi

sebagai berikut.

$$X_{t-1}X_t = \phi_1 X_{t-1}X_{t-1} + X_{t-1}e_t \quad (10)$$

dengan mengambil nilai harapan pada persamaan (10) akan

menghasilkan persamaan sebagai berikut.

$$E(X_{t-1}X_t) = \phi_1 E(X_{t-1}X_{t-1}) + E(X_{t-1}e_t). \quad (11)$$

Persamaan (11) dapat ditulis sebagai berikut.

$$\gamma_1 = \phi_1 \gamma_0 \quad (12)$$

dengan,

γ_0 dan γ_1 adalah notasi untuk autokorelasi populasi 0 dan 1.

Apabila kedua ruas pada persamaan (12) dibagi γ_0 maka menjadi sebagai berikut.

$$\rho_1 = \phi_1. \quad (13)$$

Jadi $\hat{\phi}_1 = \hat{\rho}_1$, ini berarti bahwa autokorelasi parsial yang pertama adalah sama dengan autokorelasi pertama dan kedua-duanya ditaksir di dalam sampel dengan r_1 . Secara umum, untuk mencari autokorelasi parsial pada *time-lag* ke-k digunakan persamaan sebagai berikut.

$$\rho_k = \frac{\gamma_k}{\gamma_0} \quad (14)$$

dengan,

ρ_k menunjukkan parameter autokorelasi parsial pada *time-lag* ke-k.

2. Aplikasi Analisis Deret Berkala

a. Penentuan keacakan data (atau nilai sisa)

Autokorelasi dapat digunakan untuk menetapkan apakah terdapat suatu pola (AR, MA, ARIMA) dalam suatu kumpulan data dan apabila tidak terdapat pada kumpulan data tersebut, maka dapat dibuktikan bahwa kumpulan data tersebut acak. Koefisien autokorelasi untuk beberapa *time-lag* diuji untuk melihat apakah nilai tersebut berbeda nyata dari nol. Nilai autokorelasi dari data yang acak akan tidak berbeda nyata dari nol.

b. Pengujian stasioneritas untuk deret berkala

Stasioneritas berarti bahwa tidak terdapat pertumbuhan atau penurunan pada data. Data secara kasarnya harus sepanjang sumbu waktu. Dengan kata lain, fluktuasi data berada di sekitar suatu nilai rata-rata yang konstan. Nilai-nilai autokorelasi dari data stasioner akan turun sampai nol sesudah *time-lag* kedua atau ketiga sedangkan untuk data yang tidak stasioner, nilai-nilai tersebut berbeda signifikan dari nol untuk beberapa periode waktu.

c. Operator *Backward Shift* / *Shift* mundur (B)

Notasi yang sangat bermanfaat dalam metode deret berkala Box-Jenkins adalah operator shift mundur (*backward shift*) dinotasikan B, yang penggunaannya adalah sebagai berikut.

$$BX_t = X_{t-1}$$

Notasi B yang dipasang pada X_t , mempunyai pengaruh menggeser data 1 periode ke belakang. Dua penerapan B untuk *shift* X akan menggeser data tersebut 2 (dua) periode ke belakang.

$$B(BX_t) = B^2 X_t = X_{t-2}$$

Operator *shift* miundur juga dapat digunakan untuk menggambarkan proses pembedaan (*differencing*). Sebagai contoh apabila suatu deret berkala tidak stasioner maka data tersebut dapat dibuat lebih mendekati stasioner dengan melakukan pembedaan pertama dari deret data. Pembedaan pertama dirumuskan sebagai berikut.

$$X'_t = X_t - X_{t-1}.$$

Dengan menggunakan operator *shift* mundur, perbedaan pertama dapat dituliskan sebagai berikut.

$$X'_t = X_t - BX_t = (1 - B)X_t.$$

Pembedaan orde kedua dirumuskan sebagai berikut.

$$\begin{aligned} X''_t &= X'_t - X'_{t-1} \\ &= (X_t - X_{t-1}) - (X_{t-1} - X_{t-2}) \\ &= X_t - 2X_{t-1} + X_{t-2}. \end{aligned}$$

Dengan menggunakan operator *shift* mundur maka perbedaan orde kedua dapat ditulis sebagai berikut.

$$\begin{aligned} X_t &= X_t - 2X_{t-1} + X_{t-2} \\ &= X_t - 2BX_t + B^2X_t \\ &= (1 - 2B + B^2)X_t. \end{aligned}$$

Pembedaan orde kedua dinyatakan oleh $(1 - B)^2$. Salah satu hal yang penting adalah bahwa perbedaan orde kedua yang dinotasikan $(1 - B)^2$ tidak sama dengan perbedaan kedua yang dinotasikan dengan $(1 - B^2)$.

d. Mengenali adanya faktor musiman dalam suatu deret berkala

Musiman didefinisikan sebagai suatu pola yang berulang-ulang dalam selang waktu yang tetap. Untuk data yang stasioner, faktor musiman dapat ditentukan dengan mengidentifikasi koefisien autokorelasi pada dua atau tiga *time-lag* yang berbeda nyata dari nol. Autokorelasi yang

secara signifikan berbeda dari nol menyatakan adanya suatu pola dalam data.

3. Metode ARIMA

Model *Autoregressive Intrgrated Moving Average* (ARIMA) merupakan metode yang secara intensif dikembangkan oleh George Box dan Gwilym Jenkins. Metode ARIMA berbeda dengan metode peramalan lain karena metode ini tidak mensyaratkan suatu pola data tertentu supaya model dapat bekerja dengan baik. Metode ARIMA akan bekerja dengan baik apabila data deret berkala yang dipergunakan bersifat dependen atau berhubungan satu sama lain secara statistik.

a. Notasi dalam Metode ARIMA

Secara umum model ARIMA dirumuskan dengan notasi sebagai berikut.

ARIMA (p, d, q)

dengan,

p menunjukkan orde atau derajat *autoregressive* (AR)

d menunjukkan orde atau derajat *differencing* (pembedaan) dan

q menunjukkan orde atau derajat *moving average* (MA).

Sedangkan untuk model ARIMA musiman secara umum dinotasikan sebagai berikut.

ARIMA (p, d, q) (P, D, Q)^s

dengan,

(p, d, q) merupakan bagian yang tidak musiman dari model

(P, D, Q) merupakan bagian yang musiman dari model

s merupakan jumlah periode permusim.

b. Model AR (ARIMA (p,0,0))

Model AR adalah model yang menggambarkan bahwa variabel dependen dipengaruhi oleh variabel dependen itu sendiri pada periode-periode sebelumnya.

Secara umum model AR mempunyai bentuk sebagai berikut.

$$X_t = \mu' + \phi_1 X_{t-1} + \phi_2 X_{t-2} + \dots + \phi_p X_{t-p} + e_t$$

dengan,

μ' = nilai konstan,

ϕ_j = parameter *autoregressive* ke-j,

e_t = nilai kesalahan pada saat t.

Orde dari model AR yang diberi notasi p ditentukan oleh jumlah periode variabel dependen yang masuk dalam model. Model AR (*autoregressive*) merupakan model yang mirip dengan persamaan regresi. Hanya saja yang menjadi variabel independen bukan variabel lain yang berbeda dari variabel dependen melainkan nilai sebelumnya dari variabel dependen itu sendiri.

c. Model MA (ARIMA (0,0,q))

Secara umum model MA mempunyai bentuk sebagai berikut.

$$X_t = \mu + e_t - \theta_1 e_{t-1} - \theta_2 e_{t-2} - \dots - \theta_q e_{t-q}$$

dengan,

μ merupakan konstanta, e_{t-k} merupakan nilai kesalahan pada saat t-k,

θ_1 sampai θ_q merupakan parameter-parameter *moving average*.

Perbedaan model MA dengan model AR terletak pada jenis variabel independen. Bila variabel independen dalam model AR adalah nilai sebelumnya maka pada model MA adalah nilai residual pada periode sebelumnya. Orde dari MA yang diberi notasi q ditentukan oleh jumlah periode variabel independen yang masuk dalam model.

d. Model ARIMA (p,d,q)

Secara umum model ARIMA dapat dituliskan sebagai berikut.

$$X_t = \phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + e_t - \theta_1 e_{t-1} - \dots - \theta_q e_{t-q}.$$

Dengan operator *shift* mundur dapat ditulis sebagai berikut.

$$\phi(B)X_t = \theta(B)e_t \Leftrightarrow (1 - \phi_1 B + \dots + \phi_p B^p)X_t = (1 - \theta_1 B - \dots - \theta_q B^q)e_t.$$

Model ARIMA menggunakan nilai sebelumnya dari variabel independen maupun nilai residual periode sebelumnya. Dengan penggabungan ini diharapkan model ARIMA dapat mengakomodasi pola data yang tidak dapat diidentifikasi secara sendiri-sendiri oleh model MA atau AR. Orde dari model ARIMA ditentukan oleh jumlah

periode variabel independen baik dari nilai sebelumnya dari variabel independen maupun nilai residual periode sebelumnya.

e. Model ARIMA dan faktor musim

Secara aljabar adalah sederhana tetapi dapat berkepanjangan. Oleh sebab itu, untuk tujuan ilustrasi diambil model umum ARIMA $(1,1,1)(1,1,1)^4$ sebagai berikut.

$$(1 - \phi_1 B)(1 - \Phi B^4)(1 - B)(1 - B^4)X_t = (1 - \theta_1 B)(1 - \Theta_1 B^4)e_t. \quad (15)$$

Seluruh faktor dapat dikalikan dan model umum tersebut dapat ditulis dalam bentuk yang disebut “bentuk terurai”. Perkalian pada persamaan (15) menghasilkan persamaan sebagai berikut.

$$X_t = (1 + \phi_1)X_{t-1} + (1 + \Phi_1)X_{t-4} - (1 + \phi_1 + \Phi_1 + \phi_1\Phi_1)X_{t-5} + (\phi_1 + \phi_1\Phi_1)X_{t-6} - \Phi_1X_{t-8} + (\Phi_1 + \phi_1\Phi_1)X_{t-9} - \phi_1\Phi_1X_{t-10} + e_t - \theta_1e_{t-1} + \Theta_1e_{t-4} + \theta_1\Theta_1e_{t-5}.$$

4. Tahapan dalam metode ARIMA

a. Tahap Identifikasi

1. Pengujian stasioneritas suatu deret berkala

Nilai-nilai autokorelasi dari deret data asli dihitung. Apabila nilai tersebut turun dengan cepat ke atau mendekati nol sesudah nilai kedua atau ketiga menandakan bahwa data stasioner di dalam bentuk aslinya. Sebaliknya, apabila nilai autokorelasinya tidak turun ke nol dan tetap positif menandakan data tidak stasioner sehingga diperlukan pembedaan pertama terhadap data asli. Apabila tetap tidak stasioner dilakukan pembedaan pertama lagi.

Untuk kebanyakan tujuan praktis, suatu maksimum dari dua pembedaan akan mengubah data menjadi deret stasioner.

2. Penentuan pola yang lain

Apabila kestasioneran telah diperoleh, nilai-nilai autokorelasi dihitung untuk mengetahui pola-pola lain yang terkadang terdapat di dalamnya (yaitu selain keacakan yang tersebar di sekitar nol).

Terdapat 3 kemungkinan yang harus dipertimbangkan, yaitu :

a. mungkin faktor musiman menampakkan dengan sendirinya.

Nilai autokorelasi untuk *time-lag* setiap kuartal atau setiap tahun yang besar dan secara signifikan berbeda dari nol;

b. mungkin terungkap adanya proses AR atau MA. Pola dari autokorelasi dan autokorelasi parsialnya akan menunjukkan suatu model yang memungkinkan;

c. campuran dari ketidakstasioneran, musiman dan proses AR dan MA mungkin akan terlihat (yaitu model ARIMA yang umum).

b. Tahap Penaksiran Parameter

Setelah berhasil menetapkan identifikasi model sementara, selanjutnya parameter-parameter AR dan MA, musiman dan tidak musiman harus ditetapkan.

1. Proses tidak musiman AR (1) dan AR (2)

Untuk proses autoregresif pada orde p , persamaan Yule-Walker didefinisikan sebagai berikut.

$$\begin{aligned}\rho_1 &= \phi_1 + \phi_2 + \dots + \phi_p \rho_{p-1} \\ \rho_2 &= \phi_2 \rho_1 + \phi_3 + \dots + \phi_p \rho_{p-2} \\ &\vdots \\ \rho_p &= \phi_1 \rho_{p-1} + \phi_2 \rho_{p-2} + \dots + \phi_p\end{aligned}\tag{16}$$

dengan,

$\rho_1, \rho_2, \dots, \rho_p$ adalah autokorelasi teoritis berturut-turut untuk *time-lag* 1, 2, 3,, p ,

$\phi_1, \phi_2, \dots, \phi_p$ adalah p buah koefisien AR dari proses AR (p).

Karena nilai teoritis ρ tidak diketahui maka digantikan dengan nilai empirisnya dan kemudian digunakan untuk memecahkan nilai-nilai ϕ . Untuk proses AR (1), persamaan (16) menjadi sebagai berikut.

$$\rho_1 = \phi_1.\tag{17}$$

Jika ρ_1 yang tidak diketahui diganti dengan r_1 yang diketahui (autokorelasi empiris) diperoleh nilai taksiran parameter ϕ_1 untuk proses AR (1) sebagai berikut.

$$\hat{\phi}_1 = r_1.\tag{18}$$

Untuk proses AR (2), persamaan (16) menjadi sebagai berikut.

$$\begin{aligned}\rho_1 &= \phi_1 + \phi_2 \rho_1, \\ \rho_2 &= \phi_1 \rho_1 + \phi_2.\end{aligned}\tag{19}$$

Jika ρ_1 dan ρ_2 diganti dengan r_1 dan r_2 diperoleh nilai taksiran parameter ϕ_1 dan ϕ_2 untuk proses AR (2) sebagai berikut.

$$\begin{aligned}\hat{\phi}_1 &= \frac{r_1(1-r_2)}{1-r_1^2}, \\ \hat{\phi}_2 &= \frac{r_2-r_1^2}{1-r_1^2}.\end{aligned}\tag{20}$$

2. Proses tidak musiman MA (1)

Autokorelasi teoritis untuk proses MA (q) dapat digunakan dalam bentuk koefisien-koefisien MA sebagai berikut.

$$\rho_k = \begin{cases} \frac{-\theta_k + \theta_1\theta_{k+1} + \dots + \theta_{q-k}\theta_q}{1 + \theta_1^2 + \dots + \theta_q^2}, & k = 1, 2, \dots, q. \\ 0, & k > q. \end{cases}\tag{21}$$

Karena nilai teoritis ρ_k tidak diketahui maka nilai taksiran pendahuluan dari $\theta_1, \theta_2, \dots, \theta_q$ dapat diperoleh dengan mensubstitusikan autokorelasi empiris, r_k pada persamaan (21) dan kemudian diselesaikan.

Untuk proses MA (1), persamaan (21) menjadi sebagai berikut.

$$\rho_k = \begin{cases} \frac{-\theta_1}{1 + \theta_1^2}, & k=1, \\ 0, & k \geq 2. \end{cases}\tag{22}$$

Dengan mensubstitusikan r_1 untuk ρ_1 pada persamaan (22) diperoleh persamaan kuadrat sebagai berikut.

$$\hat{\theta}_1^2 + \left(\frac{1}{r_1}\right)\hat{\theta}_1 + 1 = 0.\tag{23}$$

Dari persamaan (23) diperoleh dua penyelesaian yang harus terletak di antara -1 dan 1.

3. Model ARIMA Campuran

Ragam dan autokovarians daripada proses ARIMA(1,1), yaitu sebagai berikut.

$$X_t = \phi_1 X_{t-1} + e_t - \theta_1 e_{t-1}. \quad (24)$$

Persamaan (24) kedua sisinya dikalikan X_{t-k} dan akan menghasilkan persamaan sebagai berikut.

$$X_{t-k} X_t = \phi_1 X_{t-1} X_{t-k} + e_t X_{t-k} - \theta_1 e_{t-1} X_{t-k}. \quad (25)$$

Bila nilai harapan dimasukan pada persamaan (25) menghasilkan persamaan sebagai berikut.

$$E(X_{t-k} X_t) = \phi_1 E(X_{t-1} X_{t-k}) + E(e_t X_{t-k}) - \theta_1 E(e_{t-1} X_{t-k}). \quad (26)$$

Jika $k = 0$ maka

$$\gamma_0 = \phi_1 \gamma_1 + E[(\phi_1 X_{t-1} + e_t - \theta_1 e_{t-1})e_t] - \theta_1 E[(\phi_1 X_{t-1} + e_t - \theta_1 e_{t-1})e_{t-1}], \quad (27)$$

karena

$$X_t = \phi_1 X_{t-1} + e_t - \theta_1 e_{t-1},$$

$$\gamma_0 = \phi_1 \gamma_1 + \sigma_e^2 - \theta_1 (\phi_1 - \theta_1) \sigma_e^2.$$

Sama halnya, apabila $k = 1$ maka

$$\gamma_1 = \phi_1 \gamma_0 - \theta_1 \sigma_e^2. \quad (28)$$

Penyelesaian dari persamaan (27) dan (28) untuk γ_0 dan γ_1 menghasilkan persamaan sebagai berikut.

$$\gamma_0 = \frac{1 + \theta_1^2 - 2\phi_1\theta_1}{1 - \phi_1^2}, \quad (29)$$

$$\gamma_1 = \frac{(1 - \phi_1\theta_1)(\phi_1 - \theta_1)}{1 - \theta_1^2}. \quad (30)$$

Hasil pembagian persamaan (29) dan (30) menghasilkan persamaan sebagai berikut.

Untuk $k = 1$,

$$\rho_1 = \frac{(1 - \phi_1\theta_1)(\phi_1 - \theta_1)}{1 + \theta_1^2 - 2\phi_1\theta_1}. \quad (31)$$

Untuk $k = 2$ diperoleh fungsi autokorelasi sebagai berikut.

$$\rho_2 = \phi_1\rho_1 \Leftrightarrow \phi_1 = \frac{\rho_2}{\rho_1}. \quad (32)$$

c. Tahap Pemeriksaan Diagnostik

Setelah tahap penaksiran dari model ARIMA sementara dilakukan, selanjutnya perlu dilakukan pemeriksaan untuk membuktikan bahwa model tersebut cukup memadai. Terdapat beberapa cara untuk melakukan hal tersebut, yaitu:

1. mempelajari nilai sisa (*residual*) untuk melihat apakah masih terdapat beberapa pola yang belum diperhitungkan. Nilai sisa (galat) yang tertinggal sesudah dilakukan pencocokan model ARIMA diharapkan hanya merupakan gangguan acak. Oleh karena itu, apabila autokorelasi dan parsial dari nilai sisa

diperoleh, diharapkan akan ditemukan (i) tidak ada autokorelasi yang nyata dan (ii) tidak ada parsial yang nyata.

2. mempelajari statistik sampling dari pemecahan optimum untuk melihat apakah model tersebut masih dapat disederhanakan.
3. *overfitting* model ARIMA, yaitu misalnya menggunakan beberapa parameter lebih banyak daripada yang diperlukan atau memilih AR orde kedua bilamana AR orde pertama telah ditetapkan.

d. Peramalan dengan Model ARIMA

Apabila model memadai maka model tersebut dapat digunakan untuk melakukan peramalan. Sebaliknya, apabila model belum memadai maka harus ditetapkan model yang lain.

E. Curah hujan

Data hujan adalah data unsur cuaca yang bervariasi menurut tempat ataupun waktu. Oleh sebab variasinya yang besar, maka harus sering diukur dalam jangkauan jarak atau periode tertentu. Curah hujan dinyatakan dalam milimeter (mm) atau inci.

Seperti pada penguapan yang juga dinyatakan dengan satuan panjang, curah hujan pun dapat diartikan sebagai lawan dari penguapan. Penguapan kandungan airnya hilang sedangkan pada curah hujan kandungan airnya bertambah.

Tinggi curah hujan diasumsikan sama disekitar tempat penakaran, luasan yang tercakup oleh sebuah penakar hujan bergantung pada homogenitas daerahnya maupun kondisi cuaca lainnya. Ketepatan asumsi ini tergantung dari kecepatan angin, keterbukaan lapangan, luas alat penampung serta tinggi alat dari permukaan tanah.

Kumpulan data curah hujan di suatu tempat sangat bernilai. Jika periode pengumpulannya makin lama maka makin banyak informasi yang diperoleh terutama nilai ekstrim tertinggi atau terendah yang pernah dicapai. Jumlah curah hujan dalam sehari sering disebut curah hujan harian.

Penakar hujan dibagi dalam 2 golongan besar, yaitu tipe manual dan tipe otomatis. Bila yang diinginkan hanya jumlah curah hujan harian maka dipakai tipe manual. Informasi lebih banyak diperoleh jika menggunakan alat yang otomatis, seperti informasi curah hujan harian, intensitas serta waktu turunnya hujan.

F. Matlab

Matlab merupakan perangkat lunak yang cocok dipakai sebagai alat komputasi yang melibatkan penggunaan matrik dan vektor. Fungsi-fungsi dalam paket perangkat lunak (*toolbox*) Matlab dibuat untuk memudahkan perhitungan tersebut. Sebagai contoh, Matlab dapat dengan mudah dipakai untuk menyelesaikan permasalahan sistem persamaan linier, program linier dengan *simpleks*, pengolahan citra hingga sistem yang kompleks seperti peramalan runtun waktu (*time series*), dan lain-lain.

Banyak model jaringan syaraf tiruan menggunakan manipulasi matriks atau vektor dalam iterasinya. Oleh karena itu Matlab merupakan perangkat lunak yang cocok dipakai. Matlab menyediakan fungsi-fungsi khusus untuk menyelesaikan model jaringan syaraf tiruan.

Secara keseluruhan Matlab memiliki 6 buah jendela sebagai berikut.

1. Jendela perintah (*command window*)

Jendela perintah merupakan tempat untuk memasukkan perintah perintah yang diinginkan.

2. Jendela daftar perintah (*command history*)

Jendela ini memuat daftar perintah yang pernah diketikkan dalam jendela perintah.

3. Jendela *Launch Pad*

Jendela ini berisi fasilitas yang disediakan Matlab untuk menjalankan paket perangkat lunak (*toolbox*) untuk menyelesaikan masalah tertentu.

4. Jendela *Help*

Dipakai jika mengalami kesulitan sewaktu memilih perintah atau formatnya.

5. Jendela Direktori

6. Jendela *Workspace*

Selain jendela-jendela tersebut, Matlab juga menyediakan fasilitas editor program yang bahasa pemogramannya mirip dengan bahasa C++.

BAB III

METODE PENELITIAN

Metode penelitian merupakan satu cara yang digunakan dalam rangka penelitian sehingga pelaksanaan penelitian dapat dipertanggungjawabkan secara ilmiah. Dengan metode penelitian, data yang diperoleh semakin lengkap untuk memecahkan masalah yang dihadapi.

Pada penelitian ini prosedur yang digunakan sebagai berikut.

A. Perumusan Masalah

Dari hasil penelaahan sumber pustaka maka permasalahan yang dapat dirumuskan adalah bagaimana melakukan peramalan curah hujan dengan menggunakan jaringan syaraf *backpropagation* dan seberapa besar tingkat keakuratan *forecast* yang dihasilkan oleh jaringan syaraf tiruan dibandingkan dengan metode deret berkala Box-Jenkins (ARIMA).

B. Pengumpulan Data

Setelah permasalahan dirumuskan, dilakukan pengumpulan data curah hujan bulanan Kabupaten Pemalang dari pos pengamatan PG. Sumberharjo yang diambil dari Badan Meteorologi dan Geofisika (BMG) Semarang. Data yang akan dianalisis dalam penelitian ini mengambil data curah hujan dari bulan Januari 1996 sampai Desember 2005 (lampiran 1).

C. Analisa Data

1. Perancangan model peramalan curah hujan menggunakan jaringan syaraf tiruan *backpropagation* terdiri dari langkah-langkah sebagai berikut.

- a Menetapkan tujuan sistem

Model jaringan yang dibangun digunakan untuk meramalkan curah hujan di Kabupaten Pemalang dari bulan Januari 2005 sampai Desember 2005.

- b Menentukan fungsi aktivasi

Fungsi sigmoid biner (log sigmoid) digunakan sebagai fungsi aktivasi pada simpul tersembunyi dan keluaran.

- c Transformasi linear data curah hujan

Data ditransformasi linear pada selang $[0.1, 0.9]$. Oleh karena itu keluaran yang dihasilkan jaringan akan berada pada nilai 0 sampai 1. Untuk mendapatkan nilai sebenarnya dari keluaran perlu dilakukan proses detransformasi linear. Nilai transformasi linear, taburan data sebelum dan setelah transformasi linear terdapat pada lampiran 2, 3 dan 4.

- d Pembagian data

Pada penelitian ini, data curah hujan bulan Januari 1996 sampai Desember 2005 dibagi menjadi data pelatihan (*training*), pengujian (*testing*) dan validasi. Persentase data pelatihan adalah 60 % dari data, sejumlah 72 data (bulan Januari 1996 sampai Desember 2001) dan 40 % untuk data pengujian, sejumlah 36 data (bulan Januari 2002 sampai

Desember 2004) serta validasi, sejumlah 12 data (bulan Januari 2005 sampai Desember 2005). Pola data pelatihan, pengujian dan validasi terdapat pada lampiran 5, 6 dan 7.

e Perancangan struktur jaringan yang optimum

1. Masukan untuk jaringan terdiri dari 12 simpul.
2. Satu buah simpul digunakan untuk keluaran jaringan.
3. Satu buah lapisan digunakan untuk lapisan tersembunyi jaringan.
4. Banyaknya simpul pada lapisan tersembunyi ditentukan secara *trial* dan *error* dari simpul 1 sampai 24.

f Penentuan koefisien laju pemahaman (α) dan momentum (μ)

Koefisien laju pemahaman (α) yang digunakan sebesar 0,9 dan koefisien momentum (μ) yang digunakan adalah 0,1.

g Pemilihan jaringan yang optimum dan penggunaannya pada data validasi.

2. Langkah-langkah membentuk model peramalan curah hujan dengan metode ARIMA adalah sebagai berikut.

a. Identifikasi Model

Dalam tahap ini akan dicari model yang dianggap paling sesuai dengan data curah hujan. Diawali dengan membuat plot data curah hujan yang asli, membuat *trend* analisisnya dan grafik fungsi autokorelasi (FAK) serta fungsi autokorelasi parsial (FAKP). FAK dan FAKP digunakan untuk menentukan kestasioneran dan pola lain yang terkandung pada deret berkala.

b. Penaksiran Parameter

Tahap selanjutnya setelah menentukan model awal teridentifikasi adalah mencari taksiran terbaik atau paling efisien untuk parameter dalam model awal.

c. Pemeriksaan Diagnostik

Dalam tahap ini akan diperiksa apakah model yang diestimasi cukup sesuai dengan data yang dipunyai. Apabila terdapat penyimpangan yang cukup serius harus dirumuskan kembali model yang baru yang selanjutnya ditaksir nilai parameternya dan diperiksa.

d. Peramalan dengan model ARIMA

Setelah pemeriksaan diagnostik maka model yang terpilih dapat digunakan untuk melakukan peramalan curah hujan bulan Januari 2005 sampai Desember 2005.

3. Membandingkan tingkat keakuratan *forecast* atau ramalan yang dihasilkan oleh metode jaringan syaraf tiruan *backpropagation* dan metode deret berkala Box-Jenkins (ARIMA).

D. Penarikan Simpulan

Pada akhir pembahasan dilakukan penarikan simpulan sebagai jawaban dari permasalahan bagaimana melakukan peramalan curah hujan dengan menggunakan jaringan syaraf tiruan *backpropagation* dan seberapa besar

tingkat keakuratan *forecast* atau ramalan yang dihasilkan oleh jaringan syaraf tiruan *backpropagation* dibandingkan metode deret berkala Box-Jenkins (ARIMA).

BAB IV

HASIL PENELITIAN DAN PEMBAHASAN

A. Hasil Penelitian

1. Analisis pemilihan struktur jaringan yang optimum dan penggunaannya untuk peramalan.

Hasil proses pelatihan dengan nilai $MSE = 0.0001$ sebagai ambang batas menggunakan Matlab pada jaringan dengan bilangan simpul tersembunyi yang berbeda, yaitu dari 1 sampai 24 diperoleh nilai keluaran. Nilai MAPE dan PE dihitung secara tersendiri. Hasil perhitungan nilai keluaran, MAPE dan PE diperlihatkan pada lampiran 8. Dari proses pengujian diperoleh nilai keluaran ke-24 struktur jaringan, nilai MAPE, MSE dan PE (lampiran 9).

Berdasarkan nilai MAPE dari proses pelatihan diperoleh jaringan yang optimum, yaitu jaringan dengan 11 simpul tersembunyi. Hal ini dikarenakan nilai MAPE jaringan tersebut yang terendah, yaitu 0.002493%. Keputusan ini diperkuat oleh nilai MAPE jaringan tersebut dari proses pengujian yang merupakan nilai MAPE yang terendah, yaitu 62.436403% dibandingkan struktur jaringan yang lainnya.

Jaringan dengan struktur 12 simpul masukan, 11 simpul tersembunyi dan 1 simpul keluaran (jaringan 12-11-1) akan digunakan pada data validasi, yaitu meramalkan curah hujan pada bulan Januari 2005 sampai Desember

2005. Hasil ramalan, nilai PE, nilai MAPE dan plotnya dengan data aktual terdapat pada lampiran 10.

2. Analisis data curah hujan dengan metode deret berkala Box-Jenkins

a. Tahap Identifikasi

Berdasarkan plot data (lampiran 11) dapat disimpulkan bahwa data aktual sudah cukup stasioner. Oleh karena itu, data aktual dapat digunakan untuk mencari model awal yang tepat tanpa dilakukan pembedaan. Hal ini juga ditunjukkan oleh *trend* analisis datanya (lampiran 11) yang simetris terhadap garis lurus. Nilai-nilai koefisien autokorelasi (FAK) dan parsialnya (FAKP) turun dengan cepat ke atau mendekati nol sesudah *time-lag* 2 (lampiran 12). Plot fungsi autokorelasi dan parsialnya menunjukkan bahwa kumpulan data aktual tidak acak artinya terdapat pola-pola yang lain. Nilai-nilai autokorelasi dan parsialnya menurun secara eksponensial dan terdapat 1 autokorelasi dan parsialnya yang berbeda secara signifikan dari nol. Ini menunjukkan bahwa pada kumpulan data aktual terdapat pola proses autoregresif dan *moving average* yang masing-masing berorde 1.

Dari nilai-nilai autokorelasi dan parsialnya juga diidentifikasi adanya pola musiman yang jelas selama 12 periode. Nilai $r_{12} = 0.55$ dan $r_{24} = 0.44$ yang secara signifikan berbeda dari nol menjelaskan pola tersebut. Pembedaan musiman (*seasonal difference*) dilakukan untuk menghilangkan kuatnya pengaruh musim pada autokorelasi. Hasil

pembedaan musiman terdapat pada lampiran 13. Nilai koefisien autokorelasi dari data yang telah dibedakan (lampiran 14) memperlihatkan kebanyakan musim yang dominan telah hilang. Plot fungsi autokorelasi dan parsialnya (lampiran 14) membentuk gelombang sinus, nilai r_{12} yang tinggi dan adanya proses MA(1) yang tidak musiman mempertegas adanya proses MA(1) pada bagian yang musiman.

Dari poses identifikasi diperoleh model awal , yaitu :

$$\text{ARIMA } (1,0,1)(0,1,1)^{12}$$

atau

$$(1 - \phi_1 B)(1 - B^{12}) = (1 - \theta_1 B)(1 - \Theta_1 B^{12})e_t + \mu'$$

$$(1 - B^{12} - \phi_1 B + \phi_1 B^{12})X_t = (1 - \Theta_1 B^{12} - \theta_1 B + \phi_1 \Theta_1 B^{12})e_t + \mu'$$

$$X_t - B^{12}X_t - \phi_1 BX_{t-1} + \phi_1 X_{t-13} = e_t - \Theta_1 B^{12}e_t - \theta_1 Be_t + \theta_1 \Theta_1 B^{12}e_t + \mu'$$

$$X_t = X_{t-12} + \phi_1 X_{t-1} - \phi_1 X_{t-13} - \theta_1 e_{t-1} - \Theta_1 e_{t-12} + \theta_1 \Theta_1 e_{t-13} + e_t + \mu'.$$

dengan,

μ' adalah nilai konstan.

b. Tahap Penaksiran Parameter

Penaksiran parameter dilakukan dengan *software* Minitab. Hasil perhitungannya sebagai berikut.

ARIMA model for curah hujan

Final Estimates of Parameters

Type		Coef	SE Coef	T	P
AR	1	-0.4705	0.3429	-1.37	0.173
MA	1	-0.6484	0.2953	-2.20	0.030
SMA	12	0.9060	0.0704	12.87	0.000
Constant		-2.553	2.919	-0.87	0.384

Differencing: 0 regular, 1 seasonal of order 12
 Number of observations: Original series 120, after differencing 108
 Residuals: SS = 957662 (backforecasts excluded)
 MS = 9208 DF = 104

Modified Box-Pierce (Ljung-Box) Chi-Square statistic				
Lag	12	24	36	48
Chi-Square	12.0	25.2	33.8	46.5
DF	8	20	32	44
P-Value	0.150	0.193	0.380	0.371

Diperoleh nilai $\phi = -0.4705$, $\theta = -0.6484$, $\Theta = 0.9060$ dan $\mu' = -$

2.553 sehingga persamaan model awalnya menjadi sebagai berikut.

$$X_t = X_{t-12} - 0.4705_1 X_{t-1} + 0.4705 X_{t-13} + 0.6484 e_{t-1} - 0.9060 e_{t-12} - 0.5875 e_{t-13} + e_t - 2.553.$$

c. Pemeriksaan diagnostik

Plot fungsi autokorelasi dan parsialnya dari nilai sisa (residual) model awal (lampiran 15) menunjukkan sebagian besar nilai koefisien autokorelasi dan parsialnya tidak berbeda secara nyata dengan nol. Ini berarti model awal cukup memadai untuk menggambarkan data sehingga model awal dapat digunakan untuk meramal.

d. Peramalan dengan model ARIMA

Dari proses pemeriksaan diagnostik diperoleh bahwa model ARIMA (1,0,1)(0,1,1)¹² dapat digunakan untuk meramalkan curah hujan. Model tersebut digunakan untuk meramalkan curah hujan dari bulan Januari 2005 sampai Desember 2005. Hasil ramalan, nilai PE dan MAPE terdapat pada lampiran 16.

B. Pembahasan

Berdasarkan hasil pelatihan dengan menggunakan data pelatihan diperoleh MAPE sebesar 0.002493%. Ini menggambarkan bahwa jaringan mampu mempelajari nilai taburan data dengan baik berdasarkan 60 pola data yang digunakan. Untuk data pengujian diperoleh nilai MAPE sebesar 62.436403%. Ini menggambarkan bahwa jaringan kurang mampu mempelajari taburan data dengan baik berdasarkan 24 pola data yang digunakan. Nilai ini jauh lebih besar dari nilai MAPE data pelatihan yang menandakan adanya masalah *overtraining* dalam data pengujian yang mempengaruhi keputusan data pengujian.

Berdasarkan hasil peramalan curah hujan pada bulan Januari 2005 sampai Desember 2005 dengan menggunakan jaringan syaraf tiruan dan ARIMA diperoleh nilai MAPE masing-masing, yaitu 68.99851% dan 66.19905%. Nilai MAPE hasil peramalan curah hujan dengan jaringan syaraf tiruan relatif lebih besar daripada nilai MAPE ARIMA. Nilai MAPE jaringan syaraf tiruan yang lebih besar disebabkan oleh beberapa hal sebagai berikut.

1. Transformasi linear yang digunakan pada data asli kurang sesuai. Taburan data setelah transformasi masih bisa lebih stabil lagi jika digunakan transformasi data yang lain seperti transformasi polinomial ln atau normal.
2. Komposisi pembagian data yang kurang tepat yang menyebabkan masalah *overtraining*.

Tingkat keakuratan hasil ramalan dengan metode ARIMA masih lebih baik dibandingkan dengan jaringan syaraf tiruan yang terlihat dari nilai MAPE ARIMA yang lebih kecil dari jaringan syaraf tiruan. Tetapi jaringan

syaraf tiruan memiliki hasil yang lebih baik dalam meredam *error* yang terjadi akibat adanya perubahan mendadak pada data, seperti terlihat pada hasil peramalan pada bulan Oktober 2005 yang memiliki nilai absolute PE yaitu 7.57119% yang lebih kecil dari metode ARIMA yaitu 70.93229%.

BAB V

SIMPULAN DAN SARAN

A. Simpulan

Dari hasil penelitian dan pembahasan maka penulis dapat menarik kesimpulan sebagai berikut.

1. Peramalan curah hujan dengan metode jaringan syaraf tiruan pada penelitian ini terdiri dari langkah-langkah sebagai berikut.
 - a. Transformasi linear data curah hujan.
 - b. Pembagian data curah hujan untuk data pelatihan, pengujian dan validasi.
 - c. Perancangan struktur jaringan yang optimum.
 - d. Penggunaan jaringan yang optimum yaitu jaringan dengan struktur 12 simpul masukan, 11 simpul tersembunyi dan 1 simpul keluaran untuk peramalan.

Nilai keluaran jaringan optimum yang digunakan untuk peramalan ditentukan dengan menggunakan fase 1 (propagasi maju) yang terdapat pada algoritma pelatihan *backpropagation*.

2. Dari hasil perhitungan nilai MAPE hasil peramalan curah hujan dari bulan Januari 2005 sampai Desember 2005 diperoleh 68.99851% untuk jaringan syaraf tiruan dan 66.19905% untuk ARIMA. Nilai MAPE jaringan syaraf tiruan relatif lebih besar daripada ARIMA yang

menunjukkan tingkat keakuratan hasil peramalan dengan metode ARIMA masih lebih baik dibandingkan dengan jaringan syaraf tiruan.

B. Saran

Berdasarkan hasil penelitian maka saran yang dapat disampaikan adalah sebagai berikut.

1. Transformasi data yang lain perlu dicoba untuk mendapatkan taburan data yang lebih stabil.
2. Komposisi pembagian data yang lain perlu dicoba untuk menghindari masalah *overtraining*.
3. Modifikasi pada pelatihan standar *backpropagation* selain dengan menggunakan faktor momentum perlu dicoba untuk mempercepat iterasi selama proses pelatihan jaringan.
4. Model ARIMA yang lain masih perlu diteliti untuk mendapatkan nilai *error* ramalan yang lebih kecil.

DAFTAR PUSTAKA

- Bose, N. K., dan P. Liang. 1996. *Neural Network Fundamentals with Graphs, Algorithms and Applications*. New York: McGraw-Hill.
- Halim, Siana, dan Adrian Michael Wibisono. 2000. 'Penerapan Jaringan Syaraf Tiruan untuk Peramalan'. Dalam *Jurnal Teknik Industri Vol.2*. No. 2. Hal. 106-113.
- Kanginan, Marthen. 2000. *Fisika 2000*. Jakarta: Erlangga.
- Kusumadewi, Sri. 2004. *Membangun Jaringan Syaraf Tiruan (Menggunakan Matlab dan Excel Link)*. Yogyakarta: Graha Ilmu.
- Makridakis, Spyros., Syeven C Wheelwright., dan Victor E. McGEE. 1999. *Metode dan Aplikasi Peramalan*. Terjemahan Hari Suminto. Jakarta: Binarupa Aksara.
- Nam, Ng Ching. 2003. *Ramalan Permintaan Perumahan Kos Rendah Di Kawasan Bandar Mggk-nn - Satu Pendekatan Siri Masa*. www.efka.utm.my/thesis/images/3PSM/2003/5IT/NGCHINNAMCA010029D03TT2.doc. (5 Sept. 2006)
- Nam, Ng Ching. 2003. . *Ramalan Permintaan Perumahan Kos Rendah Di Kawasan Bandar Mggk-nn - Satu Pendekatan Siri Masa*. www.efka.utm.my/thesis/images//3PSM/2003/5IT/NGCHINNAMCA010029D03TT1.doc. (5 Sept.2006)
- Sekarwati, Ade Kemal. 2004. *Jaringan Syaraf Tiruan*. <http://digilab.umm.ac.id/go.php?node=2475>. (7 Juli 2006)
- Siang, Jong Jek. 2005. *Jaringan Syaraf Tiruan dan Pemogramannya Menggunakan Matlab*. Yogyakarta: Andi Offset.
- Subiyanto. 2000. *Aplikasi Jaringan Syaraf Tiruan sebagai Metode Alternatif Prakiraan Beban Jangka Pendek*. <http://www.elektroindonesia.com/elektro/ener29.html-42k->. (10 Maret 2006).